

西南科技大学

Southwest University of Science and Technology

专业学位硕士研究生学位论文

（电子信息硕士）

面向中文电子病历的内涵质控技术研究与应用

作者姓名 孙冯

学　　号 7220210751

导　　师 黄晓芳　周祖宏

专业（领域）名称 计算机技术

答辩委员会成员 杨春明　高小明　陈永辉　何刚　吴家菊

评　阅　人 田原　于建志

2024 年 6 月

中国知网 https://www.cnki.net

分类号：　　学校代码：10619

UDC：　　密级：

西南科技大学硕士学位论文

（电子信息硕士）

面向中文电子的病历内涵质控技术研究与应用

孙冯

学科（专业）或领域名称：计算机技术

指导教师姓名、职称：黄晓芳　（教授）

校外指导教师姓名、职称：周祖宏　（高级工程师）

学生所属学院名称：计算机科学与技术学院

论文答辩日期：2024 年 6 月 3 日

中国知网　https://www.cnki.net

A Thesis of Southwest University of Science and Technology for the Degree of Master

（Master of Electronic and Information Engineering）

Research and Application of Technology for Connotation Quality Control of Chinese Electronic Medical Records

Candidate：Feng Sun

Supervisor：Xiaofang Huang

June 2024

中国知网 https://www.cnki.net

摘　要

在我国医疗体系中，病历作为记录患者完整疾病过程的重要医疗文书，其质量直接关系到医疗安全和临床研究。然而，传统的人工病历质控效率较低，且耗时较长。针对这一问题，本文开展了中文电子病历的内涵质控技术研究与应用，旨在提升电子病历质控的效率。

为了解决病历内涵质控的数据语料库缺乏的问题，本研究通过互联网收集病历数据，并对其进行数据清洗。结合《绵阳市中心医院住院病历评定标准(试行)》和卫生部印发的《病历书写基本规范》，对病历文本进行了标注分类，构建了病历内涵缺陷文本标注语料库。随后，通过对构建完成的病历内涵缺陷文本语料库进行数据分析，验证了其在病历质控领域中的可用性，最终建立了一个高质量的病历内涵缺陷文本标注语料库，为病历质控领域的自然语言处理研究提供了重要的支持和资源。

为了实现电子病历的辅助质控，本文提出了一种基于特征融合的文本分类模型。由于病历文本中复杂的上下文关系和关键信息难以提取的难题，本模型引入了 BERT（Bidirectional Encoder Representations from Transformers），以增强对句子整体含义的理解。进一步地，为了捕捉文本中的双向语义信息和有效提取局部特征，本研究在模型的编码层融合了双向长短期记忆神经网络和文本卷积神经网络。此外，为了优化关键特征的提取并减轻信息在网络传递过程中的退化问题，模型在 BERT 编码层的输出后采用了自注意力机制和残差连接算法。通过多种技术的特征融合，本模型能够更好地理解和分类病历缺陷文本。经过实验验证，充分证明了该模型在病历缺陷文本分类任务中的有效性和可行性。

最后，本文设计并实现了一个病历内涵质控系统。该系统的主要功能有病历缺陷文本检测、病历缺陷文本辅助修改、以及病历缺陷条目时间筛选和统计分析等功能。经过系统测试，结果表明该系统的各项功能均能正常运行，达到预期目标。

关键词：病历内涵缺陷文本语料；特征融合；文本分类；病历内涵质控系统

论文类型：应用研究

中国知网　https://www.cnki.net

ABSTRACT

In China's healthcare system, medical records, as an important medical document that records the complete course of a patient's illness, have a direct bearing on medical safety and clinical research. However, the traditional manual quality control of medical records is less efficient and time-consuming. To address this problem, this paper carries out the research and application of technology for connotation quality control of Chinese electronic medical records, aiming to improve the efficiency of electronic medical record quality control.

In order to solve the problem of the data corpus of the connotation quality control of medical records, this study collects medical record data through the Internet and cleans them. Combined with the “Mianyang City Central Hospital Inpatient Medical Record Evaluation Standard (Trial)” and the “Basic Specification for Medical Record Writing” issued by the Ministry of Health, the text of the medical record was labeled and classified, and the text labeling corpus of defective connotation of the medical record was constructed. Subsequently, through the data analysis of the constructed medical record connotation defective text corpus, its usability in the field of medical record quality control was verified, and finally a high-quality medical record connotation defective text annotation corpus was established, which provides important support and resources for the natural language processing research in the field of medical record quality control.

In order to realize the auxiliary quality control of electronic medical records, this paper proposes a text classification model based on feature fusion. Due to the complex contextual relationships in the medical record text and the difficulty in extracting key information, this model introduces BERT (Bidirectional Encoder Representations from Transformers) to enhance the understanding of the overall meaning of the sentence. Further, in order to capture bidirectional semantic information in text and extract local features effectively, this study fuses a bidirectional long and short-term memory neural network and a text convolutional neural network in the coding layer of the model. In addition, in order to optimize the extraction of key features and mitigate the problem of information degradation during network transmission, the model employs a self-attention mechanism and a residual connectivity algorithm after the output of the BERT coding layer. Through the feature fusion of multiple techniques, this model is able to better understand and classify the defective text of medical records. After experimental validation, the effectiveness and feasibility of the model in the task of classifying

中国知网 https://www.cnki.net

defective text in medical records are fully proved.

Finally, this paper designs and implements a quality control system for medical record connotation. The main functions of the system are medical record defective text detection, medical record defective text auxiliary modification, as well as medical record defective entry time screening and statistical analysis. After the system test, the results show that all the functions of the system can operate normally and reach the expected goal.

KEY WORDS：Medical record connotation defective text corpus；Feature fusion；Text categorization；Quality control system for medical record connotation

TYPE OF THESIS：Application Research

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 课题研究背景和意义.....1
1.2 国内外研究现状.....1
1.2.1 电子病历质量控制研究现状.....2
1.2.2 文本表示研究现状.....2
1.2.3 文本分类研究现状.....4
1.3 论文主要内容.....5
1.4 论文章节安排.....6
2 相关理论知识和技术.....8
2.1 文本分类概述.....8
2.1.1 文本分类定义.....8
2.1.2 文本分类流程.....8
2.2 文本预处理.....9
2.2.1 文本清洗.....9
2.2.2 分词.....9
2.2.3 去停用词.....9
2.3 文本表示模型.....9
2.3.1 Word2Vec 模型.....10
2.3.2 BERT 模型.....11
2.4 神经网络模型.....12
2.4.1 卷积神经网络.....12
2.4.2 循环神经网络.....13
2.4.3 注意力机制.....14
2.5 模型评价指标.....14
2.6 本章小结.....16
3 病历内涵缺陷文本标注语料的构建.....17
3.1 引言.....17
3.2 原始病历数据预处理.....17
3.2.1 病历数据收集.....17
3.2.2 病历文本的数据清洗.....18
3.3 病历缺陷文本语料构建.....19
3.3.1 病历缺陷文本语料标注规范设计.....19
3.3.2 病历文本缺陷标注.....20
3.4 病历缺陷文本标注语料的数据分析.....21

中国知网　https://www.cnki.net

3.4.1 标签数量分布.....21
3.4.2 句子长度分布.....22
3.4.3 类别-长度散点分布.....23
3.4.4 数据集可用性验证.....24
3.5 本章小结.....25
4 基于特征融合的文本分类模型设计与实现.....26
4.1 引言.....26
4.2 基于特征融合的文本分类模型.....26
4.2.1 模型总体设计.....26
4.2.2 词嵌入层.....27
4.2.3 特征融合层.....28
4.3 实验与结果分析.....31
4.3.1 实验环境和参数设置.....31
4.3.2 实验数据.....32
4.3.3 不同层词向量对分类模型的影响.....32
4.3.4 基线模型对比.....33
4.3.5 数据标签分布均衡化对模型性能的优化效果.....35
4.4 本章小结.....36
5 病历内涵质控系统的设计与实现.....37
5.1 引言.....37
5.2 系统需求分析.....37
5.3 系统功能架构设计.....38
5.4 系统数据持久化存储设计.....39
5.4.1 MySQL 数据库设计.....39
5.4.2 Neo4j 数据库设计.....40
5.5 系统关键功能模块设计.....41
5.5.1 病历缺陷文本检测模块设计.....41
5.5.2 病历缺陷文本辅助修改模块设计.....44
5.5.3 病历缺陷条目时间筛选和统计分析模块设计.....45
5.6 系统实现与测试.....46
5.6.1 病历缺陷文本检测与辅助修改功能的实现与测试.....46
5.6.2 病历缺陷条目时间筛选和统计分析功能的实现与测试.....47
5.6.3 系统非功能性测试.....49
5.7 本章小结.....49
6 结论与展望.....50
参考文献.....51

中国知网 https://www.cnki.net

1 绪论

1.1 课题研究背景和意义

随着信息技术的飞速发展，电子病历在医疗领域得到了日益广泛的应用[1]。作为一种数字化工具[2]，电子病历以电子形式记录和存储患者的医疗信息。与传统的纸质病历相比，电子病历在信息存储、检索和共享等[3]方面展现出显著优势，有效提升了医疗信息的质量和流通效率。

然而，电子病历的普及也带来了一些挑战，尤其是病历内涵质量问题[4]。病历中不准确、不完整、不规范的信息可能导致严重的医疗错误，甚至引发不良医疗结果，对患者安全和医疗服务质量构成威胁[5]。

目前，电子病历的质量控制主要依赖于人工质控，以确保病历内容的准确性、完整性和规范性。然而，人工质控存在着一定局限性：首先，人工质控易受个人主观意识、经验和认知偏差的影响，导致评判结果的不一致性和主观性；其次，由于人力和时间的限制，人工质控通常只能对少数病历进行抽查，难以实现全面覆盖；最后，质量控制人员的专业水平参差不齐，且具备临床背景和高学历的专职人才相对匮乏。

近年来，深度学习技术的迅猛发展为电子病历的自动化处理和质控提供了新的解决方案[6]。深度学习模型能够通过训练，从海量的中文病历数据中学习到特征和模式[7]，实现对病历的高效自动化处理。与人工质控相比，深度学习方法有望大幅降低人力资源的投入，并缩短质控过程的时间消耗。

1.2 国内外研究现状

在电子病历内涵质控领域，对病历缺陷文本自动检测是一个重要的研究点。传统的人工电子病历质量控制方法面临一些挑战：首先，人工审核的速度较慢，准确率不高，并且需要较长的时间来完成；其次，质量控制人员的专业水平参差不齐，而且具备临床背景和较高学历的专职质量控制人才较为匮乏。目前，在全球范围内，还没有出现广泛认可的人工智能电子病历质量控制产品。在我国，相关领域的研究还相对较少，现有的文献资料主要集中于系统设计与功能介绍，以及系统的实施效果。一些医院虽然开始尝试引入电子病历质量控制系统[8]，但其控制范围往往局限于病历的完整性和时效性等基本功能，对于提高病历书写的规范性和质量方面的贡献有限。针对这一现状，本文提出了一种基于特征融合的文本分类质控方法，旨在提高病历质控的效率和准确性。接下来，本节将从电子病历质量控制研究现状，文本表示，文本分类的相关技术角度出发，介绍相关国内外现状。

中国知网 https://www.cnki.net

1.2.1 电子病历质量控制研究现状

电子病历质量控制目前可以分为基于管理体系和基于信息技术两大类方法。在基于管理体系方面，田军等[9]提出构建住院医师参与下的盲态模式病历质量控制体系，通过质控团队重建、工作流程优化和适当奖惩措施，来有效提升病历质量和医疗服务质量。赵静等人[10]通过分析电子病历的质控问题，提出了通过人员培训、四级质量管理、考核管理办法和电子病案信息化建设等措施，全面提高病历质量，确保医疗安全和服务质量。同时，也有学者从信息技术角度出发，对电子病历系统的质量控制模块进行设计。例如，金和风等人[11]讨论了实时监控电子病历系统通过动态管理和即时纠错，提高了病历书写的及时性、完整性和质量，减少了终末检查的工作量，提升了整个病历管理的效率和质量。李晓明等人[12] 通过在电子病历前置质控系统上自定义规则，实现了从被动的事后检验到主动的事前预防的转变，有效减少了病历缺陷，提升了医疗质量管理的灵活性和效率。张瑜等人[13]提出深入理解并应用病历质量控制的标准与准则，创建一套详尽的质控规则知识库；利用自然语言处理技术对病历文档进行深层语义分析和理解。温煜等人[14]提出了一种基于人工智能技术的自动化病历质控方法，通过构建质控规则库、自动数据采集、后结构化处理和智能分析，规范病历书写流程，有效解决了人工质控的局限性，提高了病历质控的准确性和效率。尽管这些研究取得了一定的进展，然而，目前无论是国际还是国内市场，都还没有出现广泛被采用的人工智能驱动的电子病历质量控制解决方案。在中国，关于利用人工智能进行电子病历质量控制的研究还不是很普遍，现有文献多集中于系统功能描述和实施效果评估，对于人工智能技术在电子病历质控中的具体应用介绍尚显不足。

1.2.2 文本表示研究现状

文本表示是将文本数据转换为计算机可以处理和理解的表示形式。在自然语言处理中，文本通常以字符串的形式存在，但计算机无法直接理解字符串的含义，因此，文本必须被转换成一种格式，使其能够被计算机处理和理解，这通常涉及到将其表示为数值或向量的形式。文本的这种转换可以根据其表示方式分为两种主要类型：离散型和分布式。离散型表示是一种将文本表示为离散值的方法，其中每个维度对应一个特定的单词或特征，值表示该单词或特征在文本中的出现次数或其他度量。它的特点是忽略了单词之间的语义和关联性，只关注单词的频率信息，因此无法捕捉单词之间的语义关系。文本离散表示让人熟知的有独热编码、词袋模型[15](Bag-of-Words Model，BOW)以及 N 元语法。独热编码是一种常用的文本表示方法，用于将离散型数据转换为计算机能够处理的向量形式。在独热编码[16]中，每个单词或类别被表示为一个长度为词汇表大小的向量，向量中只有一个元素为 1，表示该单词或类别的位置，其他元素为 0。独热编码的优点是简单直观，易于理解和实现。它能够保留每个单词之间的独立性，不同单词之间的距离是相等的，因此适用于一些简单的文本表示任务。然而，独热

中国知网 https://www.cnki.net

编码的缺点是向量维度较高且稀疏，当词汇表较大时，独热编码会导致向量非常稀疏，浪费了大量的内存空间。词袋模型是一种常见的文本表示技术，用于将文本转化为数值型向量，以便计算机能够对其进行处理和分析。它的优点是简单易实现，能够捕捉文本中词汇的出现信息，适用于文本分类、聚类等任务。然而，词袋模型忽略了单词之间的顺序信息和语法信息[17]，导致在处理一些需要考虑单词顺序的任务时表现不佳。N元语法[18]是自然语言处理中一种常用的文本表示方法，用于捕捉文本中的局部结构和上下文信息。N 元语法将文本中连续的 n 个单词或字符视为一个单元，并将其作为一个特征进行表示。N 元语法的优点是简单易懂，能够捕捉文本中的局部信息和一定程度的语义信息，适用于一些简单的文本分类和模式识别任务。然而，N 元语法也存在一些缺点。随着 N 的增大，特征空间会呈指数级增长，导致稀疏性问题，同时增加了模型的复杂度和计算量。

最近几年，随着深度学习的发展，研究者们开始倾向于使用基于神经网络来表示文本向量。基于分布式表示的词向量概念在 1986 年首次被 Hinton [19]提出，这种表示法的优点在于它能够自动实现泛化，当网络中的权重发生变化以纳入关于某个概念的新知识时，这些变化会影响与其他概念相关的知识，网络能够自己选择模式来表示不同的概念。在连续向量表示方面，Mikolov 等人 [20] 提出的新模型架构在超大数据集连续向量表示方面，准确性显著提升，同时大幅降低了计算成本。这些向量在测试集上展现出了最先进的句法和语义词相似性测量性能。类似地， Pennington[21] 提出 GloVe（Global Vectors for Word Representation）词嵌入模型，它在矩阵分解的基础上提出，并在词语表示方面取得了显著的成果。在近些年的研究中，Peters [22] 等人首次提出动态词向量生成模型 ELMo(Embeddings fromLanguage Models)，模拟了单词的复杂特征和在不同语言环境中的变化，显著改善了多种自然语言处理问题。Radford[23]研究员提出 OpenAI GPT 模型，通过在大量无标记文本上进行生成预训练，并在特定任务上进行微调的方法，取得了在自然语言理解各种基准上显著改进的效果。GPT 使用谷歌团队提出的 Transformer[24]作为特征提取器在自然语言处理中表现出色。它利用自注意力机制实现了并行化运算处理，能够动态获取文本的词向量表示，Transformer 为自然语言处理领域带来了重大的创新和进步。Devlin [25]等人提出 BERT(Bidirectional Encoder Representations from Transformers)模型，从未标明的文本中预先训练出深度双向表征。通过在预训练的 BERT 模型上添加一个额外的输出层，可以进行微调，从而创建出更多的双向表征。Yang [26]提出 XLNet 模型通过引入自回归（autoregressive）语言机制来解决 BERT 模型的自编码机制缺点，但是比起于 BERT 模型，XLNet 模型对算力的要求更高。Umer[27]等人在多个公开数据集上使用 FastText 词嵌入技术训练卷积神经网络模型，探讨了这种方法在文本分类任务上的应用前景，结果表明这是一种非常有前景的方法。Mutinda[28]等人提出了一种结合情感词库、N-gram 特征和 BERT 表示的新型情感分类模型 LeBERT 在三个公共数据集上的实验表明其在二元情感分类任务中的

中国知网 https://www.cnki.net

F-measure 得分达到 88.73%，优于现有的最佳模型。

1.2.3 文本分类研究现状

近年来，深度学习在文本分类领域的研究成果丰硕，主要包括基于卷积神经网络(Convolutional Neural Networks，CNN)的文本分类，基于循环神经网络(Recurrent Neural Network，RNN)的文本分类，基于注意力机制的文本分类。

在基于 CNN 的文本分类研究中，Kim[29]将卷积神经网络应用于文本分类任务中，实验结果表明简单的 CNN 模型结合微调学习特定任务向量在多项基准任务上取得了良好效果。Zhang 等人[30]使用字符级卷积网络在文本分类任务上取得了具有竞争力的结果。Ma 等人[31]基于依赖关系的卷积方法，利用基于树的 n-grams 实现非局部词之间的互动，使他们的模型在情感分析和问题分类任务中均超越了其余基线，并在 TREC 准确率上取得了显著提高。最近的研究中，Guo 等人[32]提出了一种新颖的术语加权方案，结合词嵌入，显著提高了 CNN 的分类性能，并通过对不同加权方案的权重分析，深入揭示了其工作原理。Enamoto[33]等人介绍了一种名为 GM-ShorT 的通用框架，基于卷积神经网络用于多语言短文本分类。通过收集在线社交媒体数据，并结合词嵌入机制，GM-ShorT 能够有效地解决短文本分类中的挑战，如拼写错误、错别字、讽刺词语和缺乏上下文等问题。Soni[34] 等人提出了一种名为 TextConvoNet 的新型卷积神经网络架构，能够捕捉文本数据中的句内和句间 n-gram 特征，在多个文本分类数据集上表现优异。Qorich[35]等人提出了一种基于卷积神经网络的情感分析模型，发现保留停顿词和使用随机初始化方法可以提高模型的情感分类准确率。

在基于 RNN 的文本分类研究中，Tai 等人[36]提出了一种新的模型 Tree-LSTM，Tree-LSTM 是对树状结构网络拓扑的 LSTM 扩展，在语义相关性和情感定格等任务中取得优异成绩。Zhou 等人[37]提出在双向矩阵中应用二维最大池化操作，整合了时间步和特征向量两个维度的特征，在情感分析、问题分类等任务上取得了优异表现。Dieng 等人[38]提出了 TopicRNN，一种基于 RNN 的语言模型，旨在通过潜在主题直接捕捉文档中词之间的全局语义含义。TopicRNN 集成了 RNN 和潜在主题模型的优点，在词预测任务上表现优异，并可用作文档的无监督特征提取器。Johnson 等人[39]探索了一种更复杂的区域嵌入方法，利用长短期记忆网络（(Long Short-Term Memory，LSTM）来嵌入可变大小的文本区域，并在有监督和半监督设置中有效地使用 LSTM，取得了优异的性能，超过了四个基准数据集上的先前最佳结果。Edara 等人[40]提出了一种基于分布式 LSTM 神经网络的情感分析框架，可用于有效地分析来自癌症在线社区的大量推文数据，在多个数据集上展现出比传统方法更高的准确率和更快的执行效率。Zulqarnain 等人[41]提出了一种基于双状态 GRU 网络和特征关注机制的情感分析方法 TS-GRU，在多个标准数据集上实现了优于现有方法的较高情感分类准确率。

在基于注意力机制的文本分类研究中，Yang 等人[42] 提出了一种利用注意力机制的

中国知网 https://www.cnki.net

神经网络模型，该模型通过将待排序的短答案文本和参考答案文本进行编码，并计算它们之间的相似度得分。注意力机制允许模型在计算相似度时，对不同位置的词语进行不同程度的关注，从而捕捉到更细粒度的语义关系。相较于传统基于特征工程的方法，该模型在 TRECQA 数据集上表现优异，与使用额外特征的模型相比具有竞争力，并且在与额外特征结合时优于所有基准模型。Yin 等人[43]提出了一种通用的基于注意力机制的卷积神经网络用于建模一对句子，基于注意力机制的卷积神经网络结合了三种注意力机制，能够更好地捕捉句对之间的相互影响，在回答选择、释义识别和文本蕴涵等任务上取得了最先进的性能。Lin 等人[44]提出了一种使用自注意力机制提取可解释句子嵌入的新模型，将句子表示为一个二维矩阵，其中每一行都关注句子的不同部分。模型在特征识别、情感分类和文本蕴涵等任务上表现出显著的性能优势。Chen 等人[45]提出了一种基于池化的句子表示和嵌入模型，采用了最大池化、平均池化和标量自注意力等池化方法，并通过适当设计的惩罚项来减少多头注意力中的冗余，实验结果表明，该模型在四个数据集上取得了显著的性能提升。Kim 等人[46]提出了一种基于 DenseNet（Densely Connected Convolutional Networks）结构的密集连接协同注意力循环神经网络，有效地保留了原始特征和协同注意力特征，从而在句子匹配任务上取得了最先进的性能。李卫疆等人[47] 提出了一种名为 MFSA-BiLSTM 的情感分类方法，该方法基于多通道特征和自注意力机制，旨在充分利用语言知识和情感资源，并在情感分析和文档级文本分类任务中表现优异，超过其他先进方法。Huang[48]等人提出了一种新的文本分类模型 SA-SGRU，结合了改进的自注意机制、Skip-GRU 网络和优化的 CNN，在多个公共数据集上实现了优于其他方法的性能。Li[49]等人提出了一种新颖的量子自注意神经网络架构，该架构可以克服基于句法分析的量子自然语言处理模型的局限性，在文本分类等任务上表现优于现有量子自然语言处理模型和经典自注意神经网络。

1.3 论文主要内容

（1）病历内涵缺陷文本标注语料库的构建

为了实现自然语言处理技术在中文病历的应用，首先需要一个高质量的中文病历内涵缺陷文本标注语料库。而目前针对中文病历内涵质控还没有成熟的公开数据集，因此本设计从互联网上收集了中文病历，并基于《绵阳市中心医院住院病历评定标准(试行)》和卫生部关于《病历书写基本规范》的要求，经过人工标注流程，完成了语料库的构建，而且通过数据分析验证了其可用性。这一语料库的建立为后续的病历内涵质控研究提供了支持。

（2）基于特征融合的文本分类模型的研究与实现

本文提出了一种基于特征融合的文本分类模型。该模型融合了 BERT 的文本分类输出，能够更有效地理解句子的整体语义含义。同时，模型还引入了双向长短期记忆神

中国知网 https://www.cnki.net

经网络和文本卷积神经网络，可以捕捉文本中的双向语义信息，并有效提取局部特征，从而解决了病历文本中复杂的上下文关系和关键信息提取的问题。为了进一步提取病历文本的关键特征，并减轻信息在网络中传递时的退化问题，模型还引入了自注意力机制和残差连接。这种融合多种技术的特征融合方法，使得模型能够更好地理解和分类病历缺陷文本。在本文构建的病历内涵缺陷文本数据集上对模型进行了实验验证，实验结果充分证明了该模型在病历缺陷文本分类任务中的有效性和可行性。

（3）病历内涵质控系统的设计与实现

针对以上研究成果，并结合实际应用需求，本文设计并实现了病历内涵质控系统，该系统包括了病历缺陷检测，病历缺陷文本辅助修改，以及病历缺陷条目时间筛选和统计分析等功能，有效减轻了医院质控科医生的工作量，并显著提高了病历质量控制的工作效率。

1.4 论文章节安排

全文共分六个章节，内容如下：

第一章：主要介绍本课题的研究背景和意义，以及电子病历质量控制，文本表示，文本分类的国内外现状。

第二章：本章节首先对文本分类的概念和步骤进行了深入讨论，之后阐述了文本预处理的环节。紧接着，介绍了两种流行的文本表示方法 Word2Vec 和 BERT。此外，还探讨了三种常见的神经网络架构在文本分类任务中的应用。最后，对深度学习中常使用的模型评价指标进行了介绍。

第三章：本章主要描述了病历内涵缺陷文本标注语料的构建过程。首先，介绍了病历数据的获取、清洗等预处理方式。接着，根据《绵阳市中心医院住院病历评定标准(试行)》和卫生部印发的《病历书写基本规范》，对病历缺陷文本语料进行了构建与标注。随后，对构建完成的病历缺陷文本标注语料进行了详细的数据分析，包括标签数量分布、句子长度分布以及类别-长度散点分布等，展示了数据的关键信息和特征。最后，通过实验验证了数据集的可用性，结果表明其在病历质控领域中的有效性。

第四章：在本章中详细介绍了一个基于特征融合的文本分类模型，包括模型总体设计、词嵌入层和特征融合层的具体实现。在该模型中，特征融合层发挥了关键作用，引入了 BERT 的文本分类输出，使模型在理解句子整体含义时更为有效。模型还结合了双向长短期记忆神经网络和文本卷积神经网络，以捕捉文本中的双向语义信息并有效提取局部特征。同时，为了提取文本的关键特征和减轻信息在网络中传递时的退化问题，模型引入了自注意力机制和残差连接。这种结合多种技术的特征融合层使模型能够更好地理解和分类病历缺陷文本，从而提高分类性能。

第五章：本章介绍了本文成功设计并实现了一个病历内涵质控系统，系统的核心

中国知网 https://www.cnki.net

功能包括病历缺陷检测、病历缺陷文本辅助修改、以及病历缺陷条目时间筛选和统计分析等，大大提高了病历质控的效率。通过直观的用户界面和强大的后端处理能力，该系统能大大减少医院质控科医生的工作量。

第六章：本章概述了本文研究的主要成果和贡献，并展望了电子病历内涵质控领域的未来工作。

中国知网 https://www.cnki.net

2 相关理论知识和技术

2.1 文本分类概述

2.1.1 文本分类定义

在深度学习领域，文本分类是一项监督学习任务[50]，旨在将文本分配到预定的类别中。为实现这一目标，训练数据集必须包含标注好的文本样本及其对应的类别标签。通过对这些训练文本进行特征分析，可以创建文本的特征性描述。随后，分类模型通过学习文本特征与标签之间的对应关系，构建特征到类别的映射。训练完成后，该模型能够基于特征相似度，将未知文本分配到相应的类别，从而实现自动文本分类。

2.1.2 文本分类流程

文本分类是一项用于自动将文本分配到预定义类别的自然语言处理技术。该过程包括多个阶段，从数据收集开始，经过数据清洗和特征提取，再到模型的创建、训练和评估，最终实现模型在实际场景中的应用。为了获得最优的分类性能，通常需要根据具体的应用场景和数据特性，选择和调整适合的技术和模型。具体步骤如下：

（1）数据的收集和预处理：数据的收集包含文本内容和标签的训练数据集，数据集需要经过标注，以便用于模型的训练和评估。对文本数据进行清洗和预处理，这些步骤有助于降低数据的噪音和维度，提高文本分类的效果。

（2）特征提取：将文本数据转换为可供模型训练使用的特征表示。常用的特征提取方法包括词袋模型、词嵌入[51]等。

（3）模型构建：根据任务需求和数据特点选择合适的分类模型，常用的如基于逻辑回归，随机森林等分类模型。

（4）模型训练：对构建好的模型选择合适的数据集进行训练。在模型的训练过程中，需要不断调试模型参数，以便模型能够准确地学习将文本特征映射到正确的类别标签上。

（5）模型评估：在对已经训练完成的模型进行性能评价时，通常会利用一个独立的评估数据集。这个数据集包含了真实的标签信息，可以用来验证模型的预测准确性。

（6）模型应用：首先需要加载一个预先训练好的分类模型。加载模型后，将用户提供的文本内容输入到该模型中。模型利用其在学习阶段获得的特征和规律，对输入文本进行类别预测和判断。在预测过程中，模型会分析文本的特征，并根据这些特征输出一个预测得到的类别标签，这个标签代表了文本最有可能归属的类别。最终，模型将这个类别标签作为输出结果，直接提供给用户或集成到应用程序中，从而完成整个文本分类的自动化功能。

中国知网 https://www.cnki.net

2.2 文本预处理

2.2.1 文本清洗

文本清洗是自然语言处理中的一个重要步骤，它涉及将原始文本数据转换为更干净、更结构化的格式，以便于后续的分析、建模。这一步骤包括：通过文本清洗技术减少噪声，提高数据质量，识别并处理文本中的重复条目，以避免分析中的偏差等操作。

2.2.2 分词

相对于英文文本，中文文本的复杂性要求更加注意词语的组合和语法结构，以准确理解和处理中文文本的含义。在中文文本分类中，通常采用三种主要的分词方法：

基于字符串匹配的分词[52]方法：通过事先准备好的词典或规则进行匹配，将文本分割成词语。这种方法简单直接，但对新词或专有名词的处理较为困难。

基于统计的分词[53]方法：根据语料库中词语的频率和组合情况，采用统计模型来判断汉字之间的切分位置，从而实现分词。这种方法能够较好地处理新词和专有名词，但对语料库的质量和规模要求较高。

基于理解的分词[54]方法：利用自然语言处理技术对文本进行深层次的语义分析，从而识别出词语的边界。这种方法能够更准确地理解文本的含义，但计算量较大，实现难度较高。

由于本文需要对应用场景更深层次的语义理解，因此本文所采用的是 BERT 模型的 WordPiece 分词技术。

2.2.3 去停用词

停用词，就像是在聊天时候常说的那些“嗯”、“啊”、“这个”、“那个”这样的词，它们在句子中很常见，但是它们本身并不携带太多的意义。比如，当你说“我昨天去了超市”和“我昨天去了超市买水果”，虽然两句话都有“昨天”和“了”、“去”、“了”，但是这些词并不告诉具体发生了什么，真正重要的是“超市”和“买水果”。

在处理病历文本的时候，也会碰到类似的情况。病历里会有很多专业术语，比如“右髋部”、“左上肢”，这些是重要的信息。但是，有些词就像“的”、“和”、“是”这样的，它们帮助句子读起来更流畅，但并不告诉病人的具体病情。所以，在分析病历的时候，就会把这些不太有用的词去掉，这样就可以更专注于那些真正重要的信息了。

2.3 文本表示模型

文本的表示方法主要分为两种：离散式和分布式。在离散式表示中，每个词通过独热编码转换为一个高维的稀疏向量，其中仅有一个元素是 1，其余元素均为 0。这种方法虽然直接易懂，但容易引发维度过高的问题，并且难以表达词与词之间的语义联系。

中国知网 https://www.cnki.net

相反，分布式表示法用低维的密集向量来表示词，这种表示方式更有效地反映了词之间的语义关联。本小节将深入探讨两种广泛使用的文本表示模型：Word2Vec 和 BERT，并对它们的工作原理进行详细阐述。

2.3.1 Word2Vec 模型

Word2Vec 是一种常用的词嵌入模型，它通过训练神经网络来学习每个词的低维稠密向量表示，该模型包含两种主要的架构：连续词袋模型（Continuous Bag of Words，CBOW）以及跳字模型（Continuous Skip-gram Model，Skip-gram）。两者结合起来可以有效地学习词向量，使得相似含义的词在向量空间中距离较近。模型架构如图 2-1 所示。

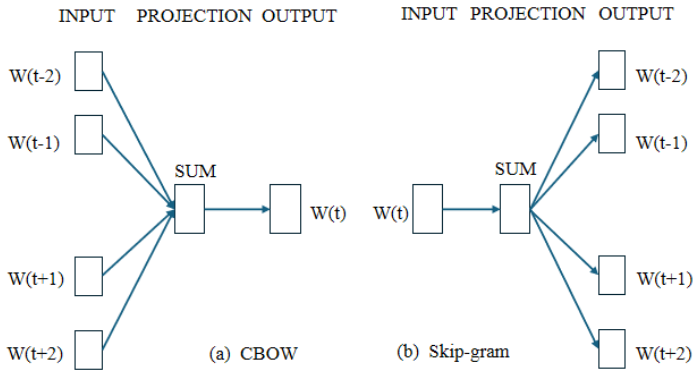


图 2-1 词袋模型和跳字模型结构

CBOW 模型与 Skip-Gram 模型在架构上具有共通之处，它们都包含输入层、隐藏层以及输出层这三个基本组成部分。尽管两者的目标和训练方式有所区别，但它们的基本神经网络框架是类似的。它们的输入层都接收词汇表中的词的编码，隐藏层用于处理输入信息，输出层用于生成模型的输出。两者在训练过程中的目标和方法不同之处，在于 CBOW 模型是利用一个词周围的上下文词汇来推断该词的向量表示。具体操作是，模型的输入层取得上下文中的一系列词，并将它们转换成独热编码形式，这些独热编码随后被转换为对应的词向量。这些词向量在加权平均后形成隐藏层的输入，而模型的输出层则基于这个输入生成目标词的向量表示。相比之下，Skip-Gram 模型的工作方式是利用给定的中心词来预测其上下文中的词汇，从而为这些上下文词汇生成向量表示。它的输入层接收当前词的独热编码，并将其映射为当前词的词向量作为隐藏层的输入，然后输出上下文词汇的词向量。

CBOW 模型中，通过计算词向量v_{w_t}和上下文词向量平均值c_t内积，并经过$softmax$函数以获得当前词w_t的条件概率分布，公式如（2-1）所示。

中国知网 https://www.cnki.net

$$p(w_t \mid c_t) = softmax(v'^T_{w_t} c_t) = \frac{\exp(v^T_{w_t} c_t)}{\sum_{w' \in v} \exp(v^T_{w_t} c_t)} \tag{2-1}$$

对 CBOW 模型的训练数据集中的每个样本，计算预测当前词的对数概率，并将其累加，然后取其相反数作为损失函数，最小化该损失函数可以使得模型更好地预测当前词，公式如（2-2）所示。

$$L = -\frac{1}{T} \sum_{t-1}^{T} \log p(w_t \mid c_t) \tag{2-2}$$

在 Skip-gram 模型中，目标是为词汇表中的每个单词学习一个词向量，这样，当有一个特定的单词w_t时，模型能够精确地推断出在其上下文中特定距离位置j处的单词w_{t+j}出现的可能性。简而言之，Skip-gram 模型旨在通过学习单词的向量表示来预测给定单词上下文中相邻单词的概率。计算公式如（2-3）所示。

$$p(w_{t+j} \mid w_t) = softmax(v^T_{w_t} v'_{w_{t+j}}) = \frac{\exp(v^T_{v_t} v'_{w_{t+j}})}{\sum_{w' \in v} \exp(v_{w_t^T} v'_{w'})} \tag{2-3}$$

skip-gram 模型的训练损失函数计算公式如（2-4）所示。

$$L = -\frac{1}{T} \sum_{t-1}^{T} \sum_{-n \le j \le n, j \ne 0} \log p(w_{t+j} \mid w_t) \tag{2-4}$$

2.3.2 BERT 模型

BERT 模型是一种革命性的自然语言处理模型，它通过结合深度学习和大规模数据预训练的方法，实现了对文本数据的高效理解和处理。其架构示意图如图 2-2 所示。BERT 的预训练分为两个主要阶段。首先是 Masked Language Model（MLM）阶段，在此阶段，模型的输入文本中会选择一些词进行遮蔽处理，然后模型需要做的就是猜测这些被遮蔽的词原本是什么。其次是 Next Sentence Prediction（NSP）阶段，模型在此阶段的任务是确定两个给定的句子是否在原始文本中是相邻的。通过这两个阶段的训练，BERT 能够学习到丰富的语言表示，包括词汇的语义、句子的语境等信息。

BERT 在预训练之后，可以通过微调来适应特定的下游任务，如文本分类、命名实体识别等。通过在下游任务上微调 BERT 模型，可以获得在特定任务上表现优异的模型，而无需从头开始训练。

BERT 模型主要提供两种输出形式：pooler output 和 sequence output。pooler output 是通过对 BERT 最后一个隐藏层的特征进行处理得到的向量，通常用于句子级别的任务，如文本分类。Sequence output 模式是将 BERT 模型中每个隐藏层的输出进行拼接，

中国知网 https://www.cnki.net

从而构建一个完整的序列，这种方式保留了序列中每个单词的上下文信息，适合于那些需要对整个文本序列进行分析和处理的任务。

在本研究中，采用了 BERT 作为词嵌入层，以表征中文电子病历文本中的词汇。因为 BERT 模型可以同时考虑一个词的上下文信息，从而能更好地理解词汇的含义和上下文语境，有助于更好地理解和处理中文文本。

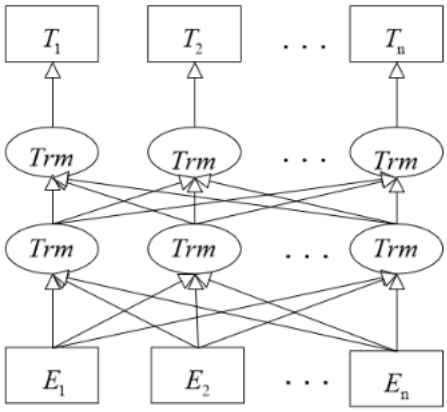


图 2-2 Bert 模型结构

2.4 神经网络模型

2.4.1 卷积神经网络

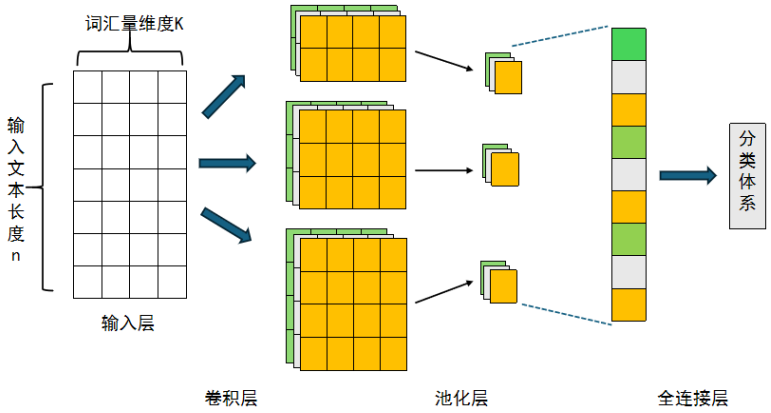


图 2-3 TextCNN 模型结构

卷积神经网络在图像处理领域取得巨大成功后，已被成功扩展应用于文本数据的处理。TextCNN 模型，作为将 CNN 应用于文本处理的重要模型之一，如图 2-3 所示。相较于传统的全连接神经网络，它引入了卷积层和池化层。TextCNN 利用多尺寸的卷积核在词向量上执行滑动操作，从而有效地抽取文本中的局部模式和特征。随后，通过池化操作，提取最显著的特征表示。这种结构使得 TextCNN 在文本分类任务中取得了

中国知网 https://www.cnki.net

显著的成果，并开启了文本分类领域的新篇章。

模型的具体层级结构如下：

（1）输入层: 输入层接收文本数据的表示，通常是词向量矩阵。每个词可以用一个向量来表示，这些向量组成了输入层的矩阵表示。

（2）卷积层: 卷积层的主要作用是识别并抽取文本数据中的局部模式。在 TextCNN 模型里，会采用多个尺寸各异的卷积核对文本进行卷积处理。每个卷积核都会生成一个特征图，这样就能够捕捉到不同长度的 n-gram 特征。卷积层输出的特征图大小是由卷积核的尺寸和步幅共同决定的。

（3）池化层: 池化层用于降低特征图的维度，保留最重要的特征。在 TextCNN 中，通常使用最大池化(max-pooling)操作。最大池化操作通过从每个特征图中选取最高值来代表该特征，以此确保最突出的特征得以保留。

（4）全连接层: 全连接层用于将池化层的输出进行扁平化，并将其映射到预定义的类别标签上。通常，全连接层会将所有特征都连接到输出层，以便进行分类。在 TextCNN 中，全连接层通常包括一个或多个全连接层和一个 softmax 层，用于生成类别预测的概率分布。

2.4.2 循环神经网络

在应用 CNN 进行文本分类时，固定大小的卷积核只能捕捉局部特征，难以充分处理文本中的长距离依赖。为了克服这一限制，研究者们引入了 RNN。RNN 通过递归处理序列数据，有效地捕捉序列信息，特别适合处理具有序列特性的文本数据。RNN 具备记忆能力，能够在处理当前输入时，同时考虑到之前的文本信息，并将这些历史信息整合到当前的输出中，从而能够处理长距离的文本依赖。RNN 的操作是按照时间序列顺序逐步展开的，如图 2-4 中展示。在每个时间步 t，RNN 的隐藏层输出$\boldsymbol{h}_t$和网络的输出$\boldsymbol{o}_t$可以通过公式（2-5）和（2-6）来计算。

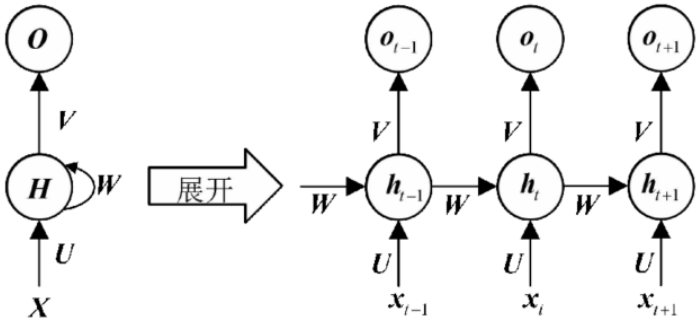


图 2-4 循环神经结构图

$$\boldsymbol{h}_t = f(\mathrm{U}\mathrm{x}_t + \mathrm{W}\mathrm{h}_{t-1} + b) \tag{2-5}$$

中国知网 https://www.cnki.net

$$\boldsymbol{o}_t = g(V\boldsymbol{h}_t) \tag{2-6}$$

训练 RNN 时使用反向传播算法更新权重和偏置，以提高网络性能。然而，循环神经网络具有循环结构，这使得网络能够随时间推移不断更新其内部状态，这导致了一些问题。其中两个主要问题是梯度消失或梯度爆炸的问题。

在反向传播算法中，误差会从输出层向输入层传播。在循环神经网络中，由于循环连接的存在，误差会沿着时间步长逐步传播回网络的早期时间步长。在这个过程中，如果梯度在传播过程中不断地乘以小于 1 的数值，就会导致梯度逐渐消失，使得网络无法学习到长期依赖关系。相反，如果梯度不断地乘以大于 1 的数值，就会导致梯度爆炸，使得网络参数的更新过于剧烈，导致训练不稳定。

为了应对梯度消失和梯度爆炸的问题，研究人员提出了一些解决方法。一种方法是采用梯度裁剪，即限制梯度的大小，确保在梯度更新时不会出现过大的变化，从而防止梯度爆炸的问题。另一种方法是使用更复杂的循环神经网络结构，如门控循环单元（Gated Recurrent Unit，GRU）和 LSTM，它们能够有效地处理序列数据中的长期依赖问题，并缓解梯度消失的问题。本文在处理病历内涵缺陷文本分类问题时，采用了双向长短期记忆神经网络（BiLSTM），这是一种特别设计的循环神经网络结构，在第四章的 4.2.3 小节中，将详细阐述 LSTM 和 BiLSTM 的工作原理和计算细节。

2.4.3 注意力机制

注意力机制使模型能够动态地集中关注当前任务中更重要的输入部分，与传统神经网络对每个部分一视同仁的方式不同，注意力机制可以使模型根据输入的不同部分的重要性来调整处理的方式，进而能提升模型在解析复杂问题时的精确度和工作效率。

注意力机制有多种形式，如自注意力[55]、多头注意力[56]、细粒度注意力[57]等。它们属于不同的注意力机制，可以使模型能够更加细致地关注输入序列的不同部分，捕捉序列内部关系，更有效地分配注意力，并在处理长序列时减少计算成本，同时更全局地聚焦输入序列。

在本研究中，采用了自注意力机制来处理病历缺陷文本的分类问题。这种机制是深度学习领域的一项重要进展，它通过为文本中的每个词赋予不同的注意力权重，揭示了词与词之间的相互关系，从而有效地提取了文本的关键特征。这使得模型能够更加精确地区分不同的文本类别。关于自注意力机制的具体计算细节，将在第四章的 4.2.3 小节中进行详细阐述。

2.5 模型评价指标

在深度学习任务中，常用混淆矩阵对分类结果进行评估，混淆矩阵是用于评估分类模型预测结果与实际标签之间关系的二维矩阵。

中国知网 https://www.cnki.net

表 2-1 混淆矩阵

		预测类别	
		Positive	Negative
实际类别	True	*TP*	*FN*
	False	*FP*	*TN*

表 2-1 中，TP 表示实际和预测都为正类别，TN 表示实际和预测都为负类别，FN 表示实际为正类别但预测为负类别，FP 表示实际为负类别但预测为正类别。

这些数值能够用于评估分类模型的效能。依据前文所提及的定义，可以得出多个与分类任务紧密相关的性能评价指标：

(1) 准确率(Accuracy)：

准确率是分类模型性能指标，但在样本不平衡情况下，可能无法全面评估模型，因为偏向多数类别的分类会导致准确率较高但分类效果较差，其计算公式如（2-7）所示。

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \tag{2-7}$$

(2) 精确率(Precision):

精确率是衡量分类模型预测正例中真正正例的比例，精确率的高低反映了分类器将负样本误分类为正样本的能力，其计算公式如（2-8）所示。

$$Precision = \frac{TP}{TP+FP} \tag{2-8}$$

(3) 召回率(Recall):

召回率是评价分类模型在识别正类样本方面的有效性的一个指标，它反映了模型正确识别正类样本的概率。具体的计算方法在公式（2-9）中展示。一个高召回率意味着模型在识别正类样本方面表现较好，但这并不意味着模型的整体性能就很高。因为如果模型将许多实际上是负类的样本错误地判定为正类，这将导致假阳性率的上升。

$$Recall = \frac{TP}{TP+FN} \tag{2-9}$$

(4) F1 值(F1_score):

F1 分数是一种衡量分类模型整体性能的指标，它同时考虑了精确率和召回率两个因素，尤其适用于处理那些类别分布不均的数据集。F1 分数通过结合精确率和召回率，提供了一个更为全面的模型性能评估，使得在面对不平衡类别时，模型的评估结果更加准确和可靠。具体的计算公式如（2-10）所示。

$$F1 = \frac{2\times Precision\times Recall}{Precision+Recall} \tag{2-10}$$

中国知网 https://www.cnki.net

2.6 本章小结

本章主要介绍了文本分类的相关理论知识和技术，包括文本分类的定义、流程、预处理方法、文本表示模型以及神经网络模型，并详细阐述了模型评价指标的相关内容。

中国知网 https://www.cnki.net

3 病历内涵缺陷文本标注语料的构建

3.1 引言

为了实现自然语言处理技术在中文病历内涵质控的应用，需要建立一个高质量的中文病历内涵缺陷文本标注语料库。因此本文收集了大量中文病历，并基于《绵阳市中心医院住院病历评定标准(试行)》和卫生部关于《病历书写基本规范》的要求，完成了语料库的构建。

首先，将收集来自多个来源的病历数据，以确保数据的多样性和覆盖面。其次，对收集到的病历文本进行清洗。接下来，将定义病历内涵缺陷的类型和范围，并制定标注规范，确保标注的一致性和准确性。然后，标注人员将根据标注规范对病历文本进行缺陷的标注。最后，将进行数据分析，确保标注的数据具有可用性。

3.2 原始病历数据预处理

3.2.1 病历数据收集

数据收集作为构建病历内涵缺陷文本标注语料库的关键环节，对于后续的模型训练和分析具有基础性的影响。在本研究中，所采用的病历数据集呈现多元化的来源，确保了数据的广泛性和多样性。首先，部分数据源自 GitHub 这一开源社区平台。GitHub 作为一个广泛用于代码托管和项目协作的平台，也包含了丰富的医疗健康相关的开源数据集，本文收集了其他用户上传的电子病历数据集。其次，通过从公开的文库中收集病历文本数据，如人人文库，百度文库等。这种方法可以有效地扩展数据来源，增加数据量，从而提高数据的多样性和覆盖范围。

在收集病历数据的过程中，第一步是对病历数据进行浏览和评估，以确保其质量和可用性。在这一阶段，需要仔细查看数据的描述、数据来源、数据格式等信息，以便确定其是否适合研究目的。具体步骤如下：

首先，需要仔细阅读数据的描述，这通常包括作者或团队提供的关于数据的详细介绍。描述中可能会提到数据的用途、目标以及数据收集的方法和过程。这些信息可以帮助了解数据的背景和意义，以及数据是否与研究问题和目标相符合。

其次，要关注数据的来源。了解数据的来源可以帮助判断数据的可靠性和可信度。数据可能来自医院、研究机构、公共数据库或其他数据提供者。对于医疗数据而言，数据的来源应该是经过充分授权和合规的，以确保数据的合法性和隐私保护。

数据格式也是需要关注的重要因素。数据可能以结构化或非结构化形式存在。对于病历文本数据，通常是以文本文件、CSV 文件或数据库等形式存储。了解数据的格

中国知网 https://www.cnki.net

式可以帮助确定数据是否易于处理和分析，并决定是否需要进行数据转换或预处理。

通过仔细浏览和评估数据的描述、数据来源、数据格式，可以更好地了解数据集的特点，确定其适用性，并为后续的数据收集和分析工作做好准备。这样可以确保使用的数据具有高质量、代表性和可靠性，为后续研究提供可靠的基础。

3.2.2 病历文本的数据清洗

病历数据收集完成后需要对收集的病历数据进行清洗。首先需要进行信息筛选，从收集的病历文本中筛选出与质控任务相关的关键信息，如主诉，现病史，既往病史等文本。然后需要进行文本清洗，需要去除多余的空格、换行符、特殊字符等，以便后续处理。病历数据清洗流程如图 3-1 所示，其伪代码如表 3-1 所示。

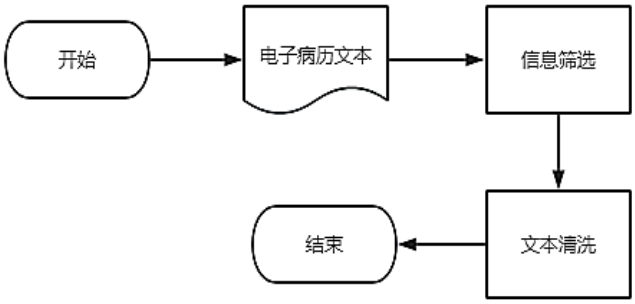


图 3-1 原始病历的数据清洗流程

表 3-1 病历数据清洗流程伪代码

输入：raw_records: 原始病历数据列表，pattern_set: 关键信息的正则表达式集合

输出：cleaned_records:清洗后的病历数据列表

```
Begin
    cleaned_records = []   //初始化清洗后列表
    for each raw_record in raw_records do
        filtered_text = PreprocessText(raw_record)
        extracted_matches = []   //初始化提取的匹配内容列表
        for each pattern in pattern_set do //正则匹配关键信息
            matches = RegexSearch(filtered_text, pattern)
            if matches is not empty then
                extracted_matches += matches   //合并匹配结果
            end if
        end for
```


中国知网 https://www.cnki.net

续表 3-1 病历数据清洗流程伪代码

```
        cleaned_text = JoinMatches(extracted_matches) //合并提取的匹配内容
        cleaned_text = RemoveFormattingNoise(cleaned_text)//去噪
        cleaned_records.append(cleaned_text)   // 存储清洗结果
    end for
return cleaned_records
end
```

3.3 病历缺陷文本语料构建

3.3.1 病历缺陷文本语料标注规范设计

病历文本的语料标注规范设计是确保标注质量和标注效率的重要步骤。本文采用人工标注的方式对病历文本进行标注，主要是缺陷类别的标注。标注过程结合《绵阳市中心医院住院病历评定标准(试行)》和卫生部发布的卫医政发[2010] 11 号文件《病历书写基本规范》，以确保标注结果的准确性和规范性。在标注过程中，标注人员需要仔细阅读病历文本，根据以上标准进行分类标注，并填写标注表格。病历缺陷文本包含的类别和标签如表 3-2 所示。

表 3-2 病历缺陷文本类别和标签

类别	标签
主诉不规范	0
主诉错误	1
现病史欠缺伴随症状描述	2
现病史发病情况描述不清	3
现病史未描述治疗经过及效果	4
现病史未描述发病以来的一般情况	5
现病史未描述与鉴别诊断有关的阳性症状	6
现病史未描述与本次入院有关的重要阴性症状	7
现病史欠缺疾病发生的先后顺序描述主要症状的部位	8
未描述疾病史	9
未描述传染病史	10
未描述预防接种史	11
未描述手术外伤史	12
未描述输血史	13
未描述食物过敏史	14

中国知网 https://www.cnki.net

续表 3-2 病历缺陷文本类别和标签

类别	标签
未描述药物过敏史	15
欠缺出生地	16
欠缺长期居留地	17
生活习惯不完整	18
工作条件不完整	19
欠缺冶游史	20
未描述婚姻状况	21
未描述配偶健康状况	22
未描述结婚年龄	23
未描述有无子女	24
女性月经史描述不完整	25
其他	26

3.3.2 病历文本缺陷标注

本文的标注工作遵循《绵阳市中心医院住院病历评定标准(试行)》和《病历书写基本规范》对病历文本进行分类标注，旨在构建一个有标签的数据集，用于训练基于特征融合的文本分类模型。首先，根据这些标准和规范整理出一套质控规则。然后，利用这些规则对清洗后的病历文本进行标注，将不规范的语句分类并标记相应的标签，如“主诉不规范”、“主诉错误”、“现病史发病情况描述不清”等。标注完成后需要再次检查，如果发现标签不合理，需要重新标注。标注流程如图 3-2 所示。

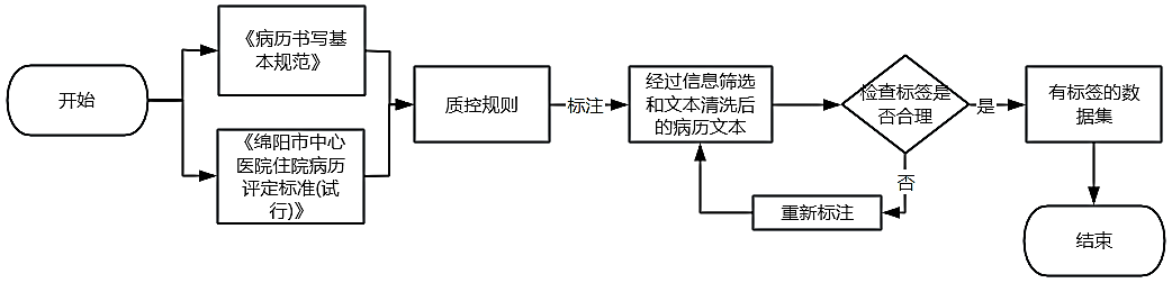


图 3-2 标注病历文本流程

由于收集的病历数量有限，且存在缺陷的病历只占其中一部分，本文采取了数据增强策略。通过分析《绵阳市中心医院住院病历评定标准(试行)》和《病历书写基本规范》，明确了缺陷类型及其关键特征。基于这些信息，本文采用了缺陷引入策略进行数据增强，如对于信息缺失，可以在病历的某些关键部分删除某些句子，对于信息错误，可以在病历关键部分引入错误的描述等策略。来最终达到病历缺陷文本数据增强的目

中国知网 https://www.cnki.net

的。

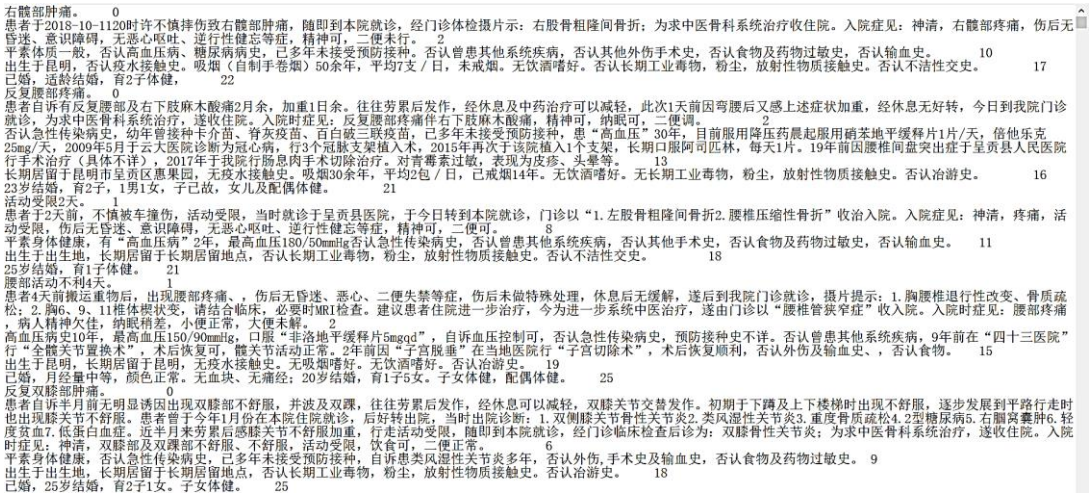
对于标注工作，本文选择使用 Excel 进行人工标注，并在标注时使用中文名称对病历内容进行标注，如图 3-3 所示。使用中文名称对条款进行标注可以帮助减少人为错误，因为中文名称更直观、易于理解和标注。



主诉		现病史		既往史		个人史		婚育史	
右髋部肿痛。	主诉不规范	患者于2018-10-1120时许不	现病史欠缺伴随症状描	平素体质一般，否	未描述传染病史	出生于昆明，否认疫水	欠缺长期	已婚，适龄结婚，育2子	未描述配偶健康
反复腰部疼痛。	主诉不规范	患者自诉有反复腰部及右下	现病史欠缺伴随症状描	否认急性传染病史	未描述输血史	长期居留于昆明市呈贡	欠缺出生	23岁结婚，育2子，1男1	未描述婚姻状况
活动受限2天。	主诉错误	患者于2天前，不慎被车撞	现病史欠缺疾病发生的	平素身体健康，有	未描述预防接种	出生于出生地，长期居生活习惯		25岁结婚，育1子体健。	未描述婚姻状况
腰部活动不利4天。	主诉错误	患者4天前搬运重物后，出	现病史欠缺伴随症状描	高血压病史10年，	未描述药物过敏	出生于昆明，长期居留	工作条件	已婚，月经量中等，颜色	女性月经史描述
反复双膝部肿痛。	主诉不规范	患者自诉半月前无明显诱因	现病史未描述与鉴别诊	平素身体健康，否	未描述疾病史	出生于出生地，长期居生活习惯		已婚，25岁结婚，育2子	女性月经史描述
胸肋、腰背部肿痛，浸	主诉不规范	患者活动受限，随即到昆明	现病史欠缺疾病发生的	平素身体健康，有	未描述输血史	出生于并长期居留于昆	工作条件	已婚，23岁结婚，育3女	女性月经史描述
活动受限2年余。	主诉错误	患者于2年前不慎跌伤致左	现病史欠缺伴随症状描	平素身体健康，无	未描述传染病史	长期居留于本地，否认	欠缺出生	已婚，初潮16岁每次持续	未描述配偶健康
活动受限1年余。	主诉错误	患者自诉有反复右肩部及肩	现病史未描述治疗经过	平素身体健康，否	未描述输血史	出生于云南昆明，无疫	欠缺长期	已婚，适龄结婚，育1子	未描述配偶健康
反复双膝部肿痛。	主诉不规范	患者自诉有反复双膝部疼痛	现病史未描述发病以来	平素身体健康，否	未描述疾病史	长期居留于昆明，否认	欠缺出生	已婚，24岁结婚，子女体	未描述有无子女
麻木10天余。	主诉错误	患者自诉10天前无明显诱因	现病史未描述发病以来	平素身体健康，患	未描述手术外伤	出生于云南，长期居留	工作条件	已婚，适龄婚育，育有1	未描述配偶健康
腰痛伴腰部活动不利。	主诉不规范	患者3小时前在公司修车时	现病史未描述治疗经过	平素身体健康，否	未描述疾病史	出生于宣威，长期居留	欠缺冶游	已婚，尚未育于女，配偶	未描述结婚年龄
间歇性脓疔一周。	主诉错误	一周前无明显诱因出现腰背	现病史未描述治疗经过	平素身体健康，否	未描述手术外伤	出生于云南昆明，长期	生活习惯	已婚，20岁结婚，育2子	未描述配偶健康
腰部疼痛。	主诉不规范	患者自诉有腰部不舒服1年	现病史未描述与鉴别诊	平素身体健康，舒	未描述输血史	长期居留于云南省昆明	欠缺出生	已婚，28岁结婚，育1女	未描述配偶健康
颈肩部疼痛伴右上肢麻	主诉不规范	患者自诉有反复颈肩部疼痛	现病史欠缺伴随症状描	平素身体健康，否	未描述预防接种	出生于云南省德宏州芒	欠缺冶游	25岁结婚，育1子，于体	未描述婚姻状况
反复颈肩部疼痛伴头晕	主诉不规范	患者自诉有反复颈肩部不舒	现病史未描述与鉴别诊	平素身体健康，否	未描述疾病史	出生于云南省昆明市，工	工作条件	已婚，月经量中等，颜色	女性月经史描述
间歇性脓疔10余年加重	主诉错误	10余年疼痛，找草医治疗突	现病史欠缺疾病发生的	平素身体健康，血	未描述食物过敏	长期居留于昆明，无疫	欠缺出生	已婚，适龄结婚，育4子	未描述结婚年龄
活动受限3小时。	主诉错误	患者缘于3小时前扭伤右踝	现病史未描述与鉴别诊	否认急性传染病史	未描述疾病史	出生于云南昆明，长期	生活习惯	已婚，初潮13岁每次持续	未描述结婚年龄
因“左盂氏骨折术后要	主诉不规范	患者缘于1年前因“左盂氏	现病史未描述治疗经过	平素身体健康，否	未描述预防接种	出生于云南，否认疫水	欠缺长期	未婚未育。	其他
扭伤致左膝关节疼痛。	主诉不规范	患者出现左膝关节肿痛，是	现病史发病情况描述不	平素身体健康，否	未描述预防接种	长期居留于昆明，无疫	欠缺出生	适龄结婚，育1子1女，三	未描述婚姻状况
腰痛伴活动不利。	主诉不规范	患者自诉于3天前不慎扭伤	现病史未描述与本次入	平素身体健康，否	未描述食物过敏	长期居留于昆明，无疫	欠缺出生	已婚，适龄婚育，育有1	未描述配偶健康

图 3-3 使用 excel 对缺陷文本进行标注

在标注完成后，需要将中文名称转换为已经定义好的病历缺陷文本类别的标签，并按照特定格式存储到文本文件中，每条信息单独成行，文本结尾处标记标签，病历内容与标签之间使用空格分隔，完成标注的病历文本如图 3-4 所示。



右髋部肿痛。 0
患者于2018-10-1120时许不慎摔伤致右髋部肿痛，随即到本院就诊，经门诊体检摄片示：右股骨粗隆间骨折；为求中医骨科系统治疗收住院。入院症见：神清，右髋部疼痛，伤后无昏迷、意识障碍，无恶心呕吐、逆行性健忘等症，精神可，二便未行。 2
平素体质一般，否认高血压病、糖尿病病史，已多年未接受预防接种。否认曾患其他系统疾病，否认其他外伤手术史，否认食物及药物过敏史，否认输血史。 10
出生于昆明，否认疫水接触史。吸烟（自制手卷烟）50余年，平均7支 / 日，未戒烟。无饮酒嗜好。否认长期工业毒物，粉尘，放射性物质接触史。否认不洁性交史。 17
已婚，适龄结婚，育2子体健， 22
反复腰部疼痛。 0
患者自诉有反复腰部及右下肢麻木酸痛2月余，加重1日余。往往劳累后发作，经休息及中药治疗可以减轻，此次1天前因弯腰后又感上述症状加重，经休息无好转，今日到我院门诊就诊，为求中医骨科系统治疗，遂收住院。入院时症见：反复腰部疼痛伴右下肢麻木酸痛，精神可，纳眠可，二便调。 2
否认急性传染病史，幼年曾接种卡介苗、脊灰疫苗、百白破三联疫苗，已多年未接受预防接种，患“高血压”30年，目前服用降压药晨起服用硝苯地平缓释片1片/天，倍他乐克25mg/天，2009年5月于云大医院诊断为冠心病，行3个冠脉支架植入术，2015年再次于该院植入1个支架，长期口服阿司匹林，每天1片。19年前因腰椎间盘突出症于呈贡县人民医院行手术治疗（具体不详），2017年于我院行肠息肉手术切除治疗。对青霉素过敏，表现为皮疹、头晕等。 13
长期居留于昆明市呈贡区惠果园，无疫水接触史。吸烟30余年，平均2包 / 日，已戒烟14年。无饮酒嗜好。无长期工业毒物，粉尘，放射性物质接触史。否认冶游史。 16
23岁结婚，育2子，1男1女，子已故，女儿及配偶体健。 21
活动受限2天。 1
患者于2天前，不慎被车撞伤，活动受限，当时就诊于呈贡县医院，于今日转到本院就诊，门诊以“1.左股骨粗隆间骨折2.腰椎压缩性骨折”收治入院。入院症见：神清，疼痛，活动受限，伤后无昏迷、意识障碍，无恶心呕吐、逆行性健忘等症，精神可，二便可。 8
平素身体健康，有“高血压病”2年，最高血压180/50mmHg否认急性传染病史，否认曾患其他系统疾病，否认其他手术史，否认食物及药物过敏史，否认输血史。 11
出生于出生地，长期居留于长期居留地点，否认长期工业毒物，粉尘，放射性物质接触史。否认不洁性交史。 18
25岁结婚，育1子体健。 21
腰部活动不利4天。 1
患者4天前搬运重物后，出现腰部疼痛、，伤后无昏迷、恶心、二便失禁等症，伤后未做特殊处理，休息后无缓解，遂后到我院门诊就诊，摄片提示：1.胸腰椎退行性改变、骨质疏松；2.胸6、9、11椎体楔状变，请结合临床，必要时MRI检查。建议患者住院进一步治疗，今为进一步系统中医治疗，遂由门诊以“腰椎管狭窄症”收入院。入院时症见：腰部疼痛，病人精神欠佳，纳眠稍差，小便正常，大便未解。 2
高血压病史10年，最高血压150/90mmHg，口服“非洛地平缓释片5mgqd”，自诉血压控制可，否认急性传染病史，预防接种史不详。否认曾患其他系统疾病，9年前在“四十三医院”行“全髋关节置换术”，术后恢复可，髋关节活动正常。2年前因“子宫脱垂”在当地医院行“子宫切除术”，术后恢复顺利，否认外伤及输血史、，否认食物。 15
出生于昆明，长期居留于昆明，无疫水接触史。无吸烟嗜好。无饮酒嗜好。否认冶游史。 19
已婚，月经量中等，颜色正常。无血块、无痛经；20岁结婚，育1子5女。子女体健，配偶体健。 25
反复双膝部肿痛。 0
患者自诉半月前无明显诱因出现双膝部不舒服，并波及双踝，往往劳累后发作，经休息可以减轻，双膝关节交替发作。初期下蹲及上下楼梯时出现不舒服，逐步发展到平路行走时也出现膝关节不舒服。患者曾于今年1月份在本院住院就诊，后好转出院，当时出院诊断：1.双侧膝关节骨性关节炎2.类风湿性关节炎3.重度骨质疏松4.2型糖尿病5.右腘窝囊肿6.轻度贫血7.低蛋白血症。近半月来劳累后感膝关节不舒服加重，行走活动受限，随即到本院就诊，经门诊临床检查后诊为：双膝骨性关节炎；为求中医骨科系统治疗，遂收住院。入院时症见：神清，双膝部及双踝部不舒服、不舒服，活动受限，饮食可，二便正常。 6
平素身体健康，否认急性传染病史，已多年未接受预防接种，自诉患类风湿性关节炎多年，否认外伤，手术史及输血史，否认食物及药物过敏史。 9
出生于出生地，长期居留于长期居留地点，否认长期工业毒物，粉尘，放射性物质接触史。否认冶游史。 18
已婚，25岁结婚，育2子1女。子女体健。 25

图 3-4 完成标注的病历文本

3.4 病历缺陷文本标注语料的数据分析

3.4.1 标签数量分布

标签数量分布是指对文本数据中标签的频率进行统计和可视化。通过分析标签的分布情况，可以了解各个类别在数据集中的相对重要性和分布情况。这对于数据集的理解、模型设计和评估都非常有帮助。图表横坐标代表不同类型的标签，纵坐标代表着

中国知网 https://www.cnki.net

每种类型标签代表的句子数量。通过绘制的训练集，验证集，测试集的标签分布图，如图 3-5 至 3-7 所示。可知所构建的病历内涵缺陷文本，主诉错误和主诉不规范这两类文本缺陷是其余缺陷文本的两到三倍。此外，其余缺陷文本标签分布较为均匀。

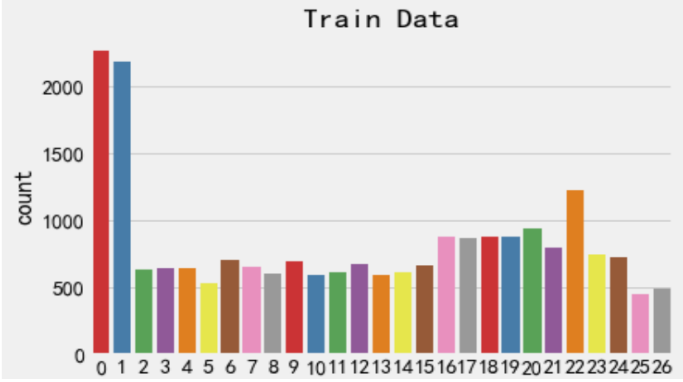


图 3-5 训练集标签数量分布

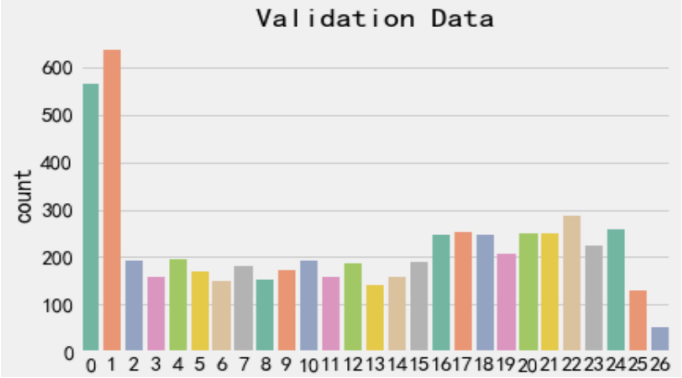


图 3-6 验证集标签数量分布

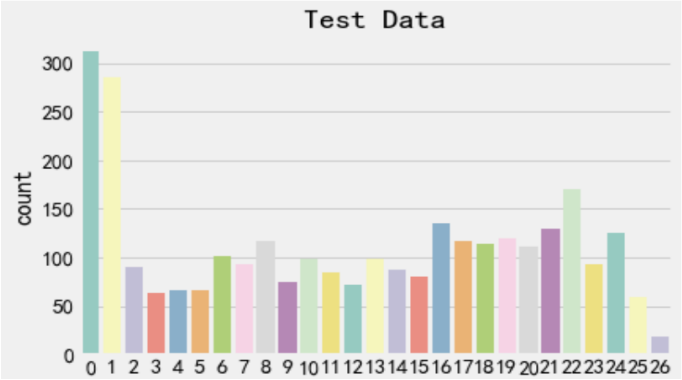


图 3-7 测试集标签数量分布

3.4.2 句子长度分布

句子长度分布是指对文本数据中句子长度的统计和可视化。通过分析句子长度的分布情况，可以了解文本数据中句子长度的变化情况以及其分布规律。

中国知网 https://www.cnki.net

根据图 3-8 所示，它展示了完成标注的病历文本长度的数量分布。该图表使用直方图来显示句子长度的分布情况，每个直方条表示具有相同长度的句子数量。通过查看这个图表，可以了解完成标注的病历文本长度的分布情况。直方图的峰值表示了句子长度分布的主要区域，而直方图的形状可以给出句子长度的整体分布趋势。这有助于了解训练数据中句子长度的范围、常见长度以及可能存在的异常情况。

根据图 3-9 所示，它是在第一个图表的基础上添加了核密度估计（Kernel Density Estimation，KDE）。KDE 是通过在每个数据点周围创建高斯核函数，并将它们叠加以估计概率密度函数的方法。KDE 曲线在图表中表示为一条平滑的曲线，可以帮助更好地理解句子长度的密度分布。KDE 曲线也可以提供关于句子长度分布的更多细节，如句子长度的峰值、分布的形状。通过观察直方图和 KDE 曲线，数据集使用者可以更全面地了解句子长度的分布情况，能更好地选择适当的模型设计策略。

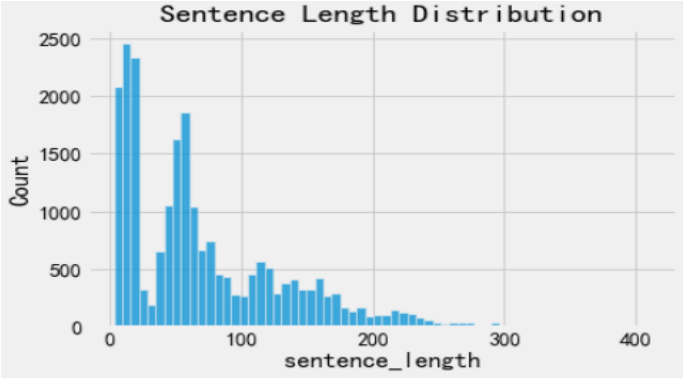


图 3-8 完成标注的病历文本长度分布（数量）

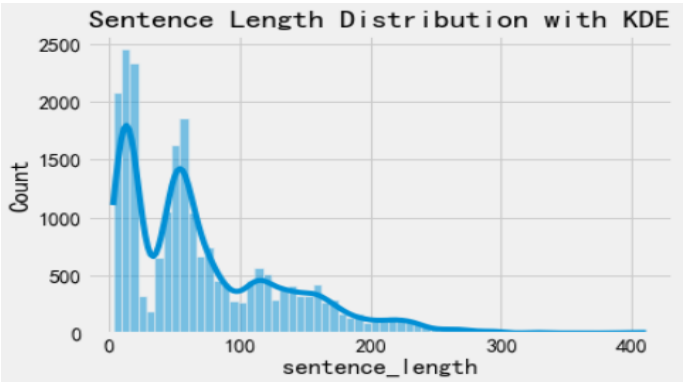


图 3-9 完成标注的病历文本长度分布（概率密度）

3.4.3 类别-长度散点分布

类别-长度散点分布是以文本数据中样本类别作为横坐标，样本的长度作为纵坐标，绘制成散点图。观察类别-长度的散点图能有效地发现数据中的异常值。图 3-10 展示了病历缺陷文本的类别-长度散点分布情况。通过观察散点图中的分布情况，可以获得关

中国知网 https://www.cnki.net

于不同类别样本长度之间的关系的直观认识。从图 3-10 中可以看到主诉错误与主诉不规范的类别样本长度较短，这是因为主诉的描述一般不超过 20 字，这与样本类别的特点相关，对于进一步的数据分析和模型建设非常有价值。

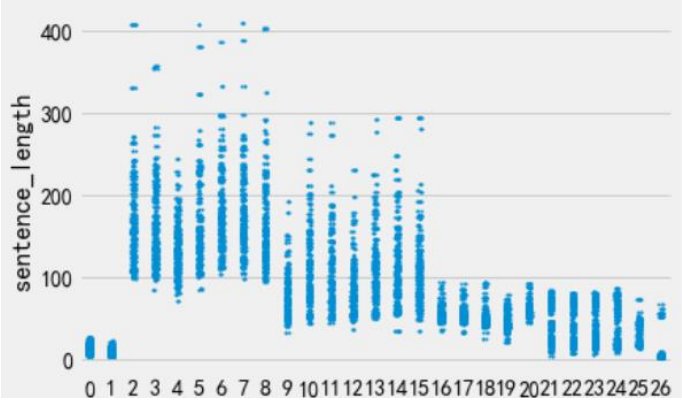


图 3-10 完成标注的病历文本类别-长度散点分布

3.4.4 数据集可用性验证

数据集质量至关重要，仅仅完成数据集构建并不意味着数据集的可用性。关键在于确保数据集的高质量标注。如果在标注过程中存在大量噪声、标签边界模糊、标注错误率高，或者标注规则过于宽松模糊，那么该数据集的可靠性和有效性将大打折扣。导致人们难以区分不同类别之间的差异，那么即使使用复杂的模型，也很难在这样的数据集上取得收敛的结果。为了确保数据集质量，标注过程应该严格执行标注规范和准确的标注标准。

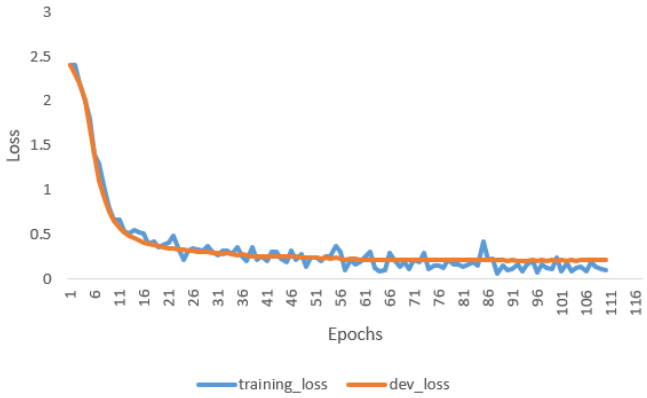


图 3-11 训练集与验证集损失

另一方面，如果数据集中存在标签泄漏或者标签与内容有直接映射关系，类别过于具体或者标注规则过于明确，那么即使使用非常简单的模型，也很容易将数据集刷到近乎满分。然而，这样的模型学到的知识可能缺乏实际意义，因为它们未必能够泛化到真实世界的复杂情况。

中国知网 https://www.cnki.net

在本次验证中，使用了 BERT 模型作为基准模型来评估病历缺陷文本语料的可用性。通过观察图 3-11 中的训练集损失和验证集损失，可以看到基准模型在本文所构建的数据集上能够正常收敛。这表明，基准模型能够有效地学习和泛化到病历缺陷文本的特征，从而在验证集上取得了良好的效果。这一结果表明，本文所构建的数据集在具备了可用性，能够支持模型的训练和评估工作。

3.5 本章小结

本章节详细描述了病历缺陷标注语料库的构建方法，涉及三个主要环节：病历文本的初步处理、病历缺陷文本语料的创建以及对这些语料的详尽分析。通过本章的工作，不仅成功地建立了一个病历缺陷文本的标注语料库，而且为后续的模型开发和病历质量控制系统的研究提供了坚实的基础。

中国知网 https://www.cnki.net

4 基于特征融合的文本分类模型设计与实现

4.1 引言

为了实现自然语言处理技术在中文病历内涵质控的应用，提升电子病历缺陷识别的效率和准确性。本章节设计了一种基于特征融合的文本分类模型。该模型设计核心在于有效整合不同层次的特征，以便捕捉病历文本中的深层次语义信息，并提升分类任务的准确性。该模型在第三章构建的病历内涵缺陷文本数据集上进行了实验验证，实验结果显示，本文提出的模型在病历缺陷文本分类任务精确性和召回率方面表现良好。

4.2 基于特征融合的文本分类模型

4.2.1 模型总体设计

本文提出的特征融合的文本分类模型，其结构如图 4-1 中所示。

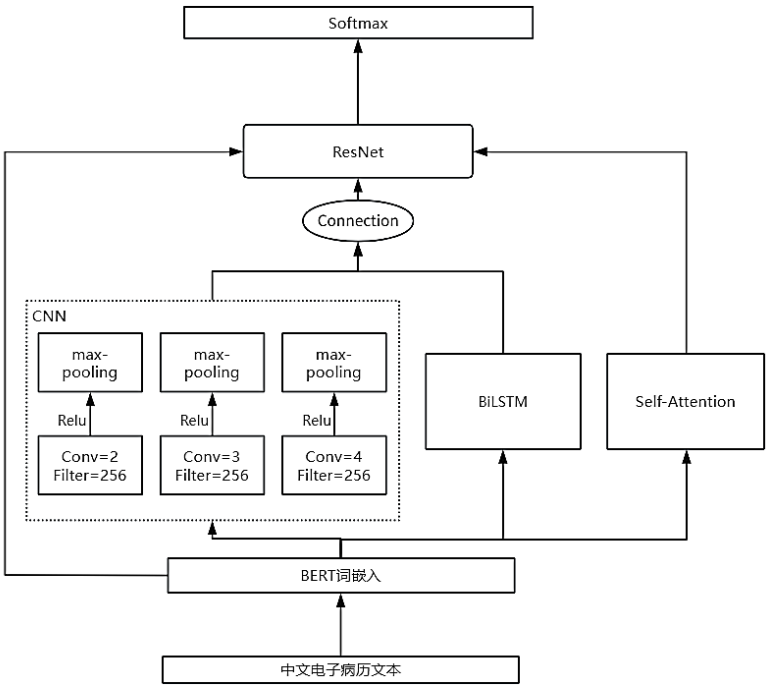


图 4-1 特征融合的文本分类模型

模型的核心是特征融合层，该层综合了 BERT 的文本分类输出、BiLSTM 和 TextCNN，并引入了自注意力机制和残差连接。BERT 的文本分类输出基于整个文本段的表示，而非单一的词或短语，这使得模型在理解句子的整体含义方面更为有效。BiLSTM 负责捕捉文本中的双向语义信息，而 TextCNN 专注于提取文本的局部特征。

中国知网 https://www.cnki.net

自注意力机制使模型能够关注文本中的关键特征，残差连接则通过加权求和不同层级的输出，促进了信息的传递和跨层级连接。这种设计使模型能够更充分地利用不同层级的特征信息，并缓解了信息在网络中传递时的退化问题。残差连接还帮助模型学习到更有效的特征表示，使得深层部分能够学习到更细粒度的特征，而浅层部分则能够捕捉到更全局的特征。

4.2.2 词嵌入层

在本文中所使用的词嵌入层是 BERT 模型，首先将经过标记处理的病历缺陷文本输入到 BERT 模型中。然后，通过 BERT 词嵌入层对文本中的每个词汇进行编码。在 BERT 中，[CLS]标记对应的词向量进行处理，以得到整个句子的表示，[SEP]用于分隔两个句子，在单个句子的场景中，也会在句子的开头和结尾添加[SEP]标记以指示句子的边界。值得说明的是，本文所使用的 BERT 模型采用 WordPiece 分词技术对词汇进行切分，将文本分割成一个个词汇单元，并将每个词汇映射到对应的词嵌入向量，过程如图 4-2 所示。这样的处理过程能够帮助 BERT 模型更好地理解中文文本的语义和上下文关系，从而提高模型在病历缺陷文本处理任务上的性能和效果。通过 WordPiece 分词的使用，模型能够更准确地捕捉到病历文本中词汇的语义特征，并将其转化为具有丰富信息的词嵌入向量，为后续的模型层级提供更有价值的输入。

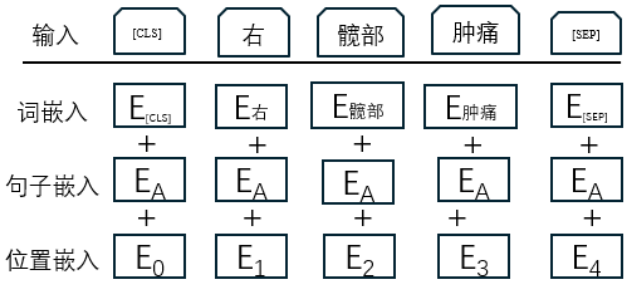


图 4-2 词嵌入结构图

BERT 编码器输出：BERT 模型的编码器是一个由多个 Transformer 层堆叠而成的结构。对于输入句子中的每个 token $\boldsymbol{x}_i$，BERT 编码器的第l层的输出$h_{i,l}$可以表示为（4-1）所示，整个序列的 token 在第 l 层的输出集合 H_l 可以表示为$H_l = \{h_{1,l}, h_{2,l}, \ldots, h_{n,l}\}$。

$$\boldsymbol{h}_{i,l} = BERT(\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_i, \ldots, \boldsymbol{x}_n) \tag{4-1}$$

式中$h_{i,l}$表示第l层对于位置i的 token 的上下文嵌入向量，n 是句子中 token 的总数。这个输出包含了句子中每个 token 的丰富上下文信息。

文本分类输出：BERT 模型在处理完所有 Transformer 层之后，通常会有一个分类层一个线性层或者一个简单的全连接层来生成文本分类输出。本文使用一个全连接层

中国知网 https://www.cnki.net

来生成文本分类输出。对于句子中代表整个句子的特定 token 即是 CLS token，其在编码器最后一层的输出$\boldsymbol{h}_{CLS,L}$会被用来进行分类，其中L是 Transformer 层的总数。文本分类输出Y_{CLS}可以通过如下计算公式表示：

$$\mathrm{Y}_{CLS} = f(\boldsymbol{h}_{CLS,L,}\ W, b) \tag{4-2}$$

式中f是一个激活函数 ReLU，W是权重矩阵，b是偏置项。Y_{CLS}是文本分类输出，是一个向量。

4.2.3 特征融合层

本文提出一种基于特征融合的分类模型，通过使用不同的模块和操作，从不同层级、不同角度提取了多种特征：首先使用 BERT 模型获取编码器的输出和文本分类输出，其中编码器的输出包含了句子的上下文信息，而文本分类输出则是 BERT 模型对句子的整体理解和分类结果。接着使用双向 LSTM 模块对编码器的输出进行了时序建模，提取了句子在不同时间步的特征表示。然后使用 TextCNN 模块对编码器的输出进行了卷积和池化操作，提取了句子中的局部特征。为了进一步突出句子中的关键信息，模型采用了自注意力机制对特征进行加权处理。最终，通过残差连接实现不同层级特征的融合，这有助于模型综合利用各种特征信息，从而提升模型的性能和表达能力。

a)TextCNN 模块

本文采用 TextCNN 来提取句子中的局部特征。TextCNN 模型的核心是卷积层和池化层的组合。卷积层通过一系列不同大小的卷积核来处理文本数据，这些卷积核能够捕捉到文本中的局部特征。在卷积操作中，卷积核沿着输入数据进行滑动，对局部区域进行加权求和，从而实现特征的提取。通过这种方式，模型能够在不同的位置捕捉到不同的特征，并且通过非线性激活函数增强了模型的表达能力。卷积操作的计算公式如式（4-3）所示。

$$y_i^d = f(\boldsymbol{W}h'_{i,l} + b_d) \tag{4-3}$$

式中$\boldsymbol{W}$是卷积核，$h'_{i,l}$是 BERT 编码器输出经过维度变换的结果，b_d是偏置项。f是 ReLU 激活函数。卷积操作的结果y_i^d表示在每个位置i上计算得到的特征。

在卷积神经网络的结构中，池化层起着至关重要的作用。它主要负责减少特征图的空间尺寸，以此降低模型的复杂度和计算需求。同时，池化层还能够提炼出输入数据中最为关键的特征，有助于提升模型的泛化能力，避免过拟合现象的发生。池化操作主要分为两种类型：最大池化和平均池化。最大池化通过从池化窗口中选取最大的元素值作为输出，这种方式有助于突出输入数据中最为显著的特征，因为这些显著特征往往与最大值相对应。而平均池化则是计算池化窗口内所有元素的平均值，并将其作为输出，这种方法可以在一定程度上减少特征图中的随机噪声，有助于模型更加稳定地

中国知网 https://www.cnki.net

学习特征，但它会忽视一些关键的细节信息。

因此本文选择了最大池化策略，计算公式如式（4-4）所示，其中 Y_d是池化窗口内的特征集合。通过这种方式，从每个特征图中提取出一个代表性的特征值，并将它们整合为一个特征集合 $\boldsymbol{S}=\{s_1,s_2,\cdots,s_n\}$，作为 CNN 层的最终输出。这样的输出不仅包含了文本数据中的核心信息，还为后续的分类任务提供了坚实的基础。

$$s_i = max\{Y_d\} \tag{4-4}$$

b)双向 LSTM 模块

在处理病历文本这类需要理解复杂上下文信息的任务时，本文引入了 BiLSTM，通过它整合文本的前向和后向信息，能够更全面地理解每个词在上下文中的含义。BiLSTM 的架构是通过结合两个独立的 LSTM 单元来实现的。LSTM（Long Short-Term Memory）是循环神经网络的一种衍生形式，它采用了独特的内部单元设计，用以克服标准 RNN 在处理长序列数据时遇到的长期依赖难题。这种结构的示意图参见图 4-3。

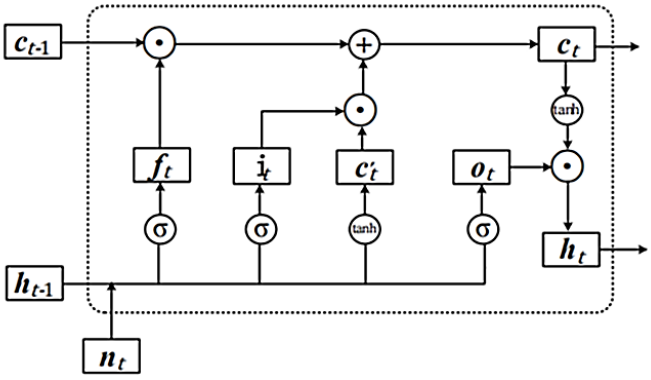


图 4-3 LSTM 单元

LSTM 循环单元内部的计算过程如式（4-5）至（4-10）所示，其中$\boldsymbol{W}$代表权重，$\boldsymbol{b}$为偏置参数，$\boldsymbol{h}_{t-1}$是前一个时间步 t 的隐藏状态，$\boldsymbol{p}_t$是当前时间步 t 的输入。$\boldsymbol{i}_t$、$\boldsymbol{f}_t$、$\boldsymbol{o}_t$分别为当前时间步 t 的输入门、遗忘门、输出门状态，$\boldsymbol{c}'_t$为当前时间步 t 的候选值，$\boldsymbol{c}_t$是当前时间步 t 的记忆细胞状态，σ是 sigmod 函数。

$$\boldsymbol{i}_t = \sigma(\boldsymbol{W}_i \cdot [\boldsymbol{h}_{t-1} + \boldsymbol{p}_t] + \boldsymbol{b}_i) \tag{4-5}$$

$$\boldsymbol{f}_t = \sigma(\boldsymbol{W}_f \cdot [\boldsymbol{h}_{t-1} + \boldsymbol{p}_t] + \boldsymbol{b}_f) \tag{4-6}$$

$$\boldsymbol{o}_t = \sigma(\boldsymbol{W}_o \cdot [\boldsymbol{h}_{t-1} + \boldsymbol{p}_t] + \boldsymbol{b}_o) \tag{4-7}$$

$$\boldsymbol{c}'_t = \tanh(\boldsymbol{W}_c \cdot [\boldsymbol{h}_{t-1} + \boldsymbol{p}_t] + \boldsymbol{b}_c) \tag{4-8}$$

$$\boldsymbol{c}_t = \boldsymbol{f}_t \cdot \boldsymbol{c}_{t-1} + \boldsymbol{i}_t \cdot \boldsymbol{c}'_t \tag{4-9}$$

$$\boldsymbol{h}_t = \boldsymbol{o}_t \cdot \tanh(\boldsymbol{c}_t) \tag{4-10}$$

BiLSTM 的特点是它能够进行双向数据流的处理，这意味着模型不仅分析文本的自然顺序，还分析其逆序。这种双向处理方式使得模型能够从两个角度学习词汇的上

中国知网 https://www.cnki.net

下文关系，从而提取更加丰富的语义特征。每个方向的 LSTM 层都能够捕捉到不同的上下文特征，这些特征随后可以被合并，以便形成一个综合的表示，这样的表示更有可能捕捉到文本中的关键信息。BiLSTM 模型图如图 4-4 所示。

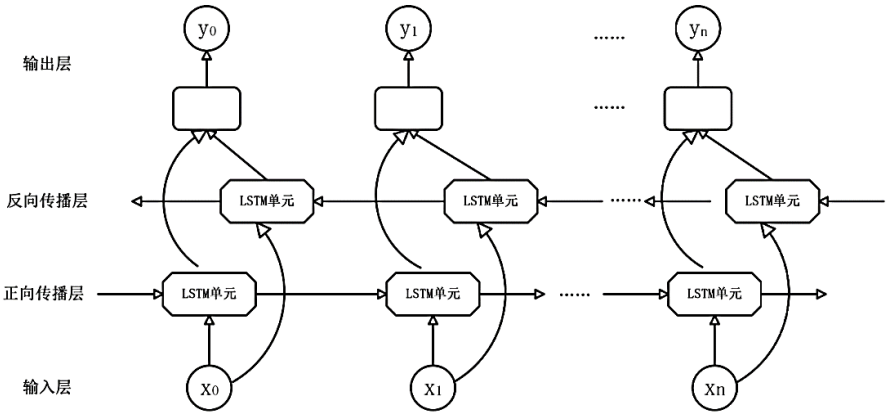


图 4-4 BiLSTM 模型图

本文利用自然顺序 LSTM 单元和逆序 LSTM 单元分别计算隐层输出$\overrightarrow{h_t}$和$\overleftarrow{h_t}$，根据之前提到的公式（4-5）至（4-10）进行计算。然后将$\overrightarrow{h_t}$与$\overleftarrow{h_t}$拼接起来，得到时间步 t 时刻的隐藏层输出$h_t = [\overrightarrow{h_t}, \overleftarrow{h_t}]$。最后，将得到整个双向 LSTM 模块的输出向量为$H = \{h_1, h_2, \dots, h_n\}$。其中每个$h_t$都是包含正向和反向上下文信息的表示。

c)自注意力机制层

在本文的研究中，自注意力机制被应用于病历缺陷文本分类任务，旨在通过自注意力机制，模型可以捕捉到输入序列内部的长距离依赖关系，并且能够自动学习并关注重要的信息。自注意力机制的目标是计算序列中每个 token 对其他所有 token 的注意力分数，并根据这些分数加权求和以得到新的表示。自注意力机制的核心是三个可学习的权重矩阵 W^Q, W^K和W^V，用于将输入表示映射到查询、键和值的空间。自注意力机制计算过程如式（4-11）至（4-14）所示，其中H_l是经过 BERT 得到的词向量，b是偏置项，d_k是键向量的维度，用于缩放点积，防止过大的点积值导致 softmax 函数的梯度接近于零。O是输出序列，包含了经过加权处理的 token 表示。

$$Q = H_l W^Q + b \tag{4-11}$$

$$K = H_l W^K + b \tag{4-12}$$

$$V = H_l W^V + b \tag{4-13}$$

$$O = Self_Attention(Q, K, V) = softmax(\frac{Q \cdot K^T}{\sqrt{d_k}})V \tag{4-14}$$

d）融合策略

本文通过特征拼接沿着特征维度的方向将 TextCNN 的输出S和 BiLSTM 的最后时间步输出H拼接起来，然后对特征拼接的结果通过一个全连接层FC进行特征整合得到

中国知网 https://www.cnki.net

一个新的张量A，其计算公式如式（4-15）。接着本文通过残差连接来实现将不同部分的输出相加，进而实现了信息的传递和跨层级的连接。BERT 编码器的输出的词向量经过自注意力机制模块，得到加权后的自注意力输出O，并通过另一个全连接层FC得到最终的自注意力输出。同时， BERT 模型的文本分类输出，通过一个全连接层得到一个独立的分类结果Y_{CLS}。最后，将融合输出 A、自注意力输出O和 BERT 的独立的分类结果Y_{CLS}相加，得到特征的深度整合输出R。其计算公式如式（4-16）所示。这样的融合策略使得模型更好地利用了不同层级的特征信息。

$$\mathrm{A} = FC(Concat(H + \mathrm{S})) \tag{4-15}$$

$$\mathrm{R} = Y_{CLS} + A + FC(O) \tag{4-16}$$

在神经网络模型中，分类层作为最后一层，负责将学习到的特征转换为具体的类别预测，本文采用softmax函数用于将最终的融合输出R 转换为类别概率分布P。计算公式如式（4-17）所示，其中W是权重矩阵，b是偏置项。

$$P = \mathrm{softmax}\ (W\mathrm{R} + \mathrm{b}) \tag{4-17}$$

4.3 实验与结果分析

4.3.1 实验环境和参数设置

实验中的硬件及软件配置如表 4-1 所示：

表 4-1 实验环境

实验环境	环境配置
操作系统	CentOS Linux release 7.8.2003 (Core)
CPU	Intel(R) Core(TM) i5-4670K CPU @ 3.40GHz
内存	16GB
GPU	NVIDIA GeForce GTX 3080Ti
编程语言	Python 3.7.12
深度学习框架	PyTorch 1.8.0
CUDA 版本	11.4

实验模型参数设置如表 4-2 所示：

表 4-2 模型参数

	TxteCNN	BiLSTM	BiLSTM+TxteCNN	OurModel
Hidden	768	768	768	768
Learning rate	1e-5	1e-5	1e-5	1e-5
Batch_size	64	64	64	64

中国知网 https://www.cnki.net

续表 4-2 模型参数

	TxteCNN	BiLSTM	BiLSTM+TxteCNN	OurModel
Epoch	30	30	30	30
Dropout	0.1	0.1	0.1	0.1
Max_length	100	100	100	100
Optimizer	Adam	Adam	Adam	Adam
卷积核尺寸	(2,3,4)	-	(2,3,4)	(2,3,4)
卷积核数量	256	-	256	256

4.3.2 实验数据

在本章中所进行的实验数据是基于第三章节所建立的病历缺陷文本标注语料库。根据该语料库，本文遵循了 70%、20%和 10%的比例原则，将数据集划分为训练集、验证集和测试集，分布情况见表 4-3。

表 4-3 训练集，验证集和测试集划分

数据集	主诉错误	主诉不规范	现病史欠缺伴随症状描述	现病史发病情况描述不清	……	女性月经史描述不完整	合计
训练集	2268	2184	639	651	……	453	22260
验证集	636	564	192	159	……	129	6000
测试集	312	285	90	63	……	60	2985

4.3.3 不同层词向量对分类模型的影响

为了探究不同层级中生成的词向量和句向量在执行文本分类任务时的效能，本文分析重点放在了 BERT 模型的第 3 层、第 6 层、第 9 层以及第 12 层的表现上。实验旨在确定适合本文文本分类任务的最优层级。实验成果已汇总于表 4-4 中。

表 4-4 不同层词向量对分类模型的影响

层数	准确率	召回率	f1 值
Layer-3	0.8068	0.8132	0.8098
Layer-6	0.8133	0.8085	0.8023
Layer-9	0.8172	0.8055	0.8115
Layer-12	0.8333	0.8215	0.8166

中国知网 https://www.cnki.net

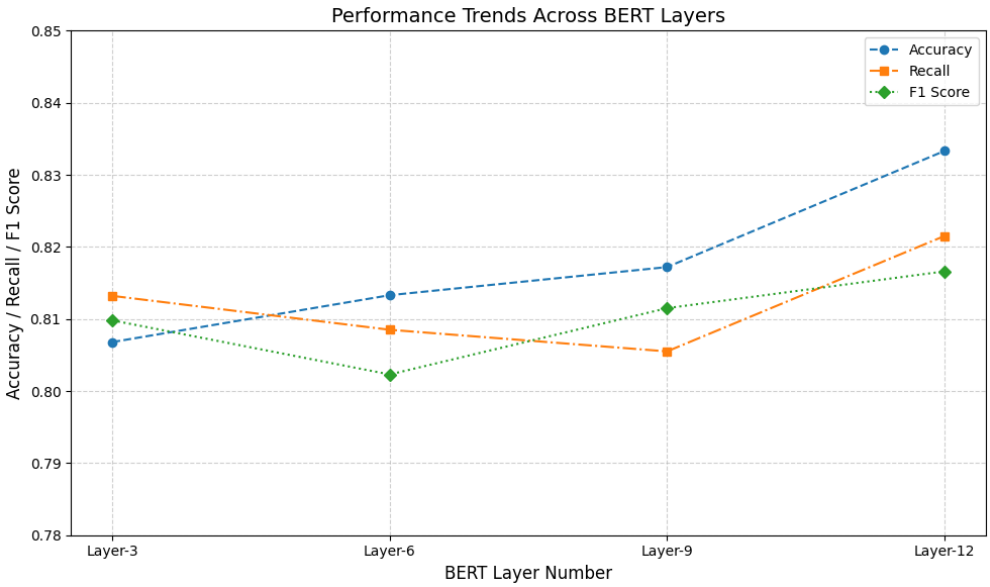


图 4-5 BERT 不同层级性能

由表 4-4 和图 4-5 可知，在病历内涵缺陷识别任务中，BERT 模型不同层级的词向量对分类性能具有显著影响。从具体数据来看，准确率、召回率和 F1 值均呈现“随层数增加逐步提升，中间层存在波动”的趋势。其中，浅层（Layer-3）的表现最弱，准确率仅为 80.68%，召回率和 F1 值分别为 81.32%和 80.98%。当使用中间层（Layer-6 和 Layer-9）时，准确率小幅提升至 81.33%和 81.72%，但召回率和 F1 值出现波动，如 Layer-6 的 F1 值下降至 80.23%，表明中间层在信息整合过程中可能引入噪声，导致模型在精确性和覆盖率之间未能达到平衡。然而，当采用最高层（Layer-12）的词向量时，所有指标均达到峰值，准确率、召回率和 F1 值分别为 83.33%、82.15%和 81.66%，显著优于其他层级。这一结果表明，BERT 的高层词向量（如 Layer-12）能够更有效地捕捉文本的全局语义和复杂上下文依赖，而浅层（如 Layer-3）更侧重于局部语法特征，难以满足医疗文本对深层语义理解的需求。中间层（Layer-6 和 Layer-9）的波动可能源于其过渡性特征，既包含浅层语法信息，又未完全整合深层语义，导致分类性能不稳定。因此，实验最终选择 Layer-12 作为词向量表示的依据不仅在于其准确率的显著提升，更在于其召回率和 F1 值的同步优化，验证了其在医疗文本任务中平衡精确性与覆盖率的综合能力。基于此，后续实验将统一采用 Layer-12 词向量进行模型架构对比，以确保基线的一致性。

4.3.4 基线模型对比

为了检验本章所提出的基于特征融合的文本分类模型在病历文本处理方面的效能，本文选择了三种基线模型作为参照，通过在本文构建的病历缺陷文本数据集上进行实验，将其与本章提出的文本分类模型进行效果比较：

a) TextCNN：TextCNN 能够有效地捕捉病历文本中的局部特征，这对于识别病历

中国知网 https://www.cnki.net

中的特定缺陷至关重要。通过使用不同大小的卷积核，TextCNN 能够同时提取文本中的 n-gram 特征，这有助于识别出病历中的关键词和短语。此外，TextCNN 的多通道卷积设计使得模型能够更全面地表示文本序列，增强了对文本信息的捕捉能力，从而在文本分类任务中提高了分类的准确性。因此选择 TextCNN 模型为基准模型，

b)BiLSTM：BiLSTM 能够处理文本的双向上下文信息，这对于理解病历文本中的复杂临床逻辑和语义关系非常重要。BiLSTM 通过其独特的门控机制，能够有效地捕捉长距离依赖关系，这对于病历文本中可能出现的复杂临床信息尤为重要。此外，BiLSTM 作为一个成熟的序列建模工具，为评估新模型提供了一个稳定的性能基准。

c)BiLSTM-TextCNN：BiLSTM-TextCNN 模型结合了 BiLSTM 的时序理解和 TextCNN 的局部特征捕捉能力，提供了一个强大的特征提取框架。这种组合模型在自然语言处理领域的文本分类任务中已被证明是非常有效的，它能够提供更丰富的特征表示，从而提高分类性能。通过将 BiLSTM-TextCNN 作为基准，可以准确地衡量所提出的特征融合分类模型在病历缺陷文本分类任务中的性能增益，验证其在病历缺陷文本分类任务上的有效性和先进性。

表 4-5 病历缺陷文本分类模型性能对比实验

模型	准确率	召回率	f1 值
BERT-TextCNN	0.7990	0.8050	0.7824
BERT-BiLSTM	0.7801	0.7935	0.7662
BERT-BiLSTM-TextCNN	0.8185	0.8150	0.7993
Our Model	0.8333	0.8215	0.8166

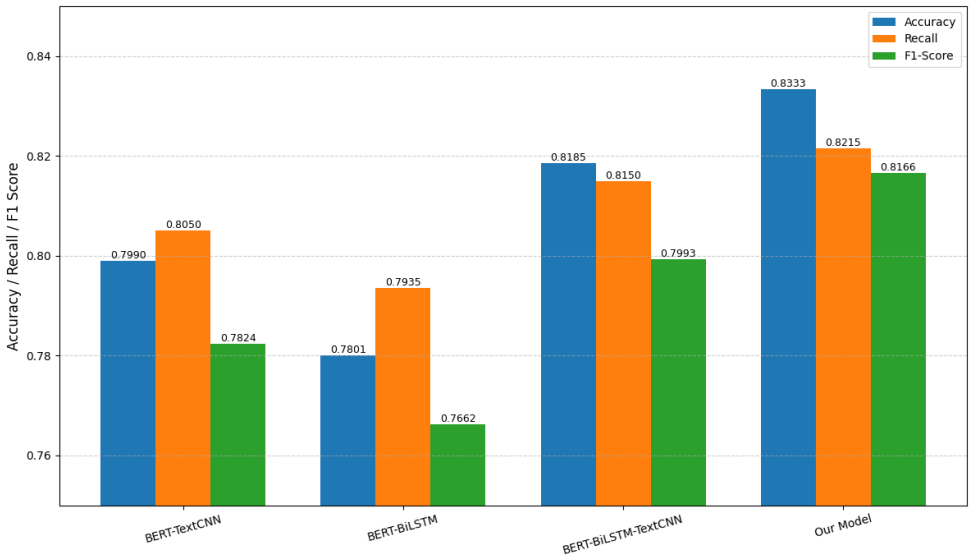


图 4-6 病历缺陷文本分类模型性能对比

中国知网 https://www.cnki.net

由表 4-5 和图 4-6 可知，在病历缺陷文本分类任务中，不同模型的设计对性能有显著影响。单一结构的模型表现较弱：BERT-TextCNN 的准确率、召回率和 F1 值分别为 79.90%、80.50%和 78.24%，而 BERT-BiLSTM 因仅依赖长序列建模能力，三项指标进一步下降至 78.01%、79.35%和 76.62%，表明单一模型难以兼顾局部特征与全局依赖。相比之下，混合模型 BERT-BiLSTM-TextCNN 通过结合 BiLSTM 的长距离依赖捕捉和 TextCNN 的局部特征提取，性能显著提升，准确率达到 81.85%，F1 值提升至 79.93%，验证了多结构协同的有效性。最终，优化后的“Our Model”在所有指标上均实现最优表现，准确率达到 83.33%、召回率达到 82.15%、F1 值达到 81.66%，在准确率上较混合模型进一步提升了近 2 个百分点。这一突破源于模型中引入特征融合策略，增强了复杂语义的捕捉能力，尤其在病历文本中需平衡专业术语的局部特征与上下文逻辑的全局关联。实验结果不仅表明混合架构在医疗文本分类中的必要性，还凸显了跨模块交互对性能提升的关键作用，为实际场景中高精度、低漏检的医疗缺陷识别提供了可靠的技术路径。基于当前模型的优化成果，下一小节将进一步探讨数据标签分布不均衡对分类性能的影响，以全面挖掘模型的潜力。

4.3.5 数据标签分布均衡化对模型性能的优化效果

通过对模型架构进行优化后，数据标签的长尾分布问题成为进一步影响性能的关键因素。如图 3.4.1 所示，原始数据集中“主诉错误”和“主诉不规范”两类标签的样本量显著高于其他缺陷类型，约为其余标签的 2-3 倍，这种不均衡分布可能导致模型过度拟合高频类别，从而削弱对罕见缺陷的识别能力。为此，本文采用数据重平衡策略，通过对头部标签的随机下采样，使各类别样本量趋于均衡，以此提升模型的泛化性能。

实验对比结果由表 4-6 可知，在消除长尾分布后，模型的分类性能得到全面优化：准确率从 83.33%提升至 84.59%，提高了 1.26%，召回率从 82.15%增至 82.65%，提高了 0.50%，F1 值从 81.66%提升至 82.78%，提高了 1.12%。这一结果表明，数据均衡化不仅缓解了模型对头部标签的偏向性，还显著增强了对尾部类别的覆盖能力。例如，在“女性月经史描述不完整”等低频缺陷的识别中，均衡后的模型能够更充分地学习其语义特征，减少漏检风险。值得注意的是，F1 值的同步提升进一步验证了均衡策略在平衡精确率与召回率上的有效性。通过降低高频标签的过拟合倾向，模型在整体分类任务中实现了更稳健的表现。这一发现为医疗文本分类场景提供了重要启示：在复杂语义与长尾分布并存的条件下，数据预处理与模型优化的协同设计是提升缺陷识别精度的关键路径。

中国知网 https://www.cnki.net

表 4-6 标签有无长尾分布的对比实验

标签分布情况	准确率	召回率	f1 值
长尾分布	0.8333	0.8215	0.8166
无长尾分布	0.8459	0.8265	0.8278

4.4 本章小结

本章详细介绍了针对特征融合的文本分类模型研究与实现。本文提出了一种基于特征融合的文本分类模型。然后在本文所构建的病历缺陷文本语料中进行验证模型的优越性，实验结果表明，本文提出的模型在病历缺陷文本分类任务上具有较高的分类准确率。

中国知网 https://www.cnki.net

5 病历内涵质控系统的设计与实现

5.1 引言

本章将详细阐述病历内涵质控系统的设计与实现过程，包括系统的需求分析，系统的功能架构设计，系统的数据持久化存储设计，系统关键功能模块设计，以及系统实现与测试。该系统采用了前文提出的基于特征融合的文本分类模型。这一算法的实施，使本文提出的算法具备了直接应用价值，大大减少了医院质控科医生的工作负担并提高病历质量控制的效率。

5.2 系统需求分析

电子病历内涵质控系统的业务需求，如图 5-1 所示。

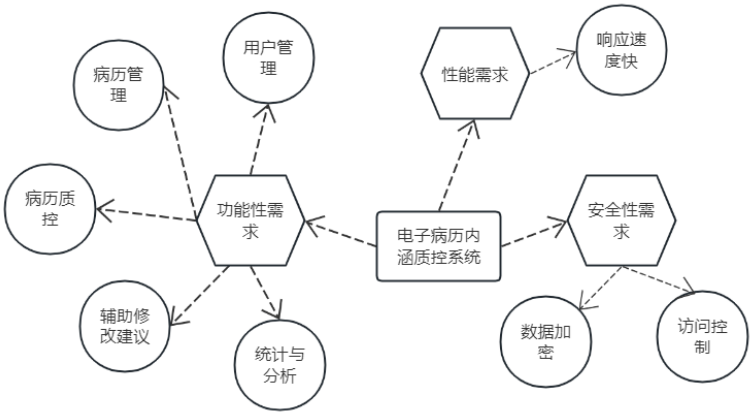


图 5-1 系统业务需求分析图

系统功能性需求分析主要是对用户管理模块，病历管理模块，病历质控模块，统计与分析模块，以及辅助修改建议模块的需求分析。

a）用户管理模块，提供一套账户服务体系，使用户能够通过一个直观的注册流程创建新账户。系统需要提供安全的登录机制和个人信息管理功能，允许用户更新联系信息及更改密码，从而保障用户账户的安全性和个人信息的私密性，此外，系统还需要根据用户角色分配不同的访问权限。

b）病历管理模块，提供了一个用户友好的界面，支持病历文档的上传、浏览、筛选、查看、下载、删除等功能。

c）病历质控模块，利用基于特征融合的文本分类模型，实现病历的缺陷检测，提高质控过程的效率。

中国知网 https://www.cnki.net

d）统计与分析模块，提供数据分析工具，使其能够对病历缺陷进行多维度分析。系统支持基于时间范围的数据筛选，并能够将统计结果以图形化的方式展现，从而帮助用户直观地理解数据。

e）辅助修改建议模块，该模块能够根据缺陷类型自动提供修改建议。

病历内涵质控系统的非功能性需求分析着重确保系统的性能与安全性。

a）系统性能方面，支持快速响应时间，确保病历上传、搜索和质控处理等关键操作在几秒内完成。

b)在数据安全与隐私保护方面，系统将对所有敏感信息进行加密，实施严格的访问控制。

5.3 系统功能架构设计

病历内涵质控系统功能架构，如图 5-2 所示。病历内涵质控系统提供了一套完整的功能，以支持用户管理、病历管理、病历质控和修改建议管理。系统允许用户注册、登录并管理个人信息，同时通过角色分配确保安全性和权限控制。病历管理功能支持病历的上传、浏览和筛选等功能。病历质控模块允许用户执行病历审核、添加、编辑和删除质控结果。修改建议管理模块支持新增、编辑和删除修改建议，并提供辅助功能以生成建议。此外，系统还提供了缺陷统计分析工具，帮助用户根据不同时间段对病历缺陷进行筛选和分析。

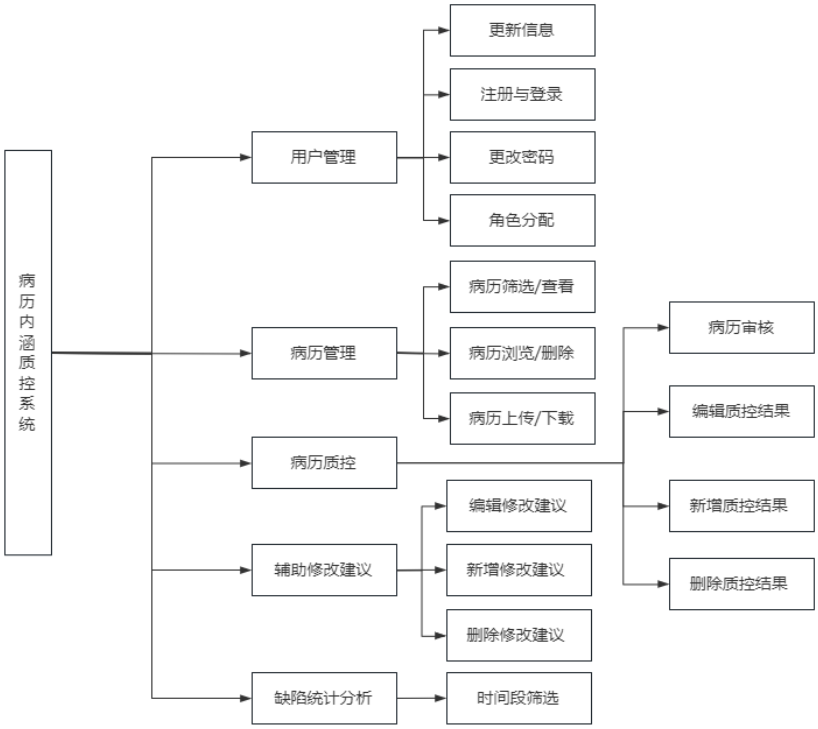


图 5-2 病历内涵质控系统功能模块图

中国知网 https://www.cnki.net

5.4 系统数据持久化存储设计

5.4.1 MySQL 数据库设计

在本系统中，根据业务需求和数据管理的特点，本文设计了 MySQL 数据表，以确保数据的有效组织。系统部分表的 E-R 图，如图 5-3 所示。

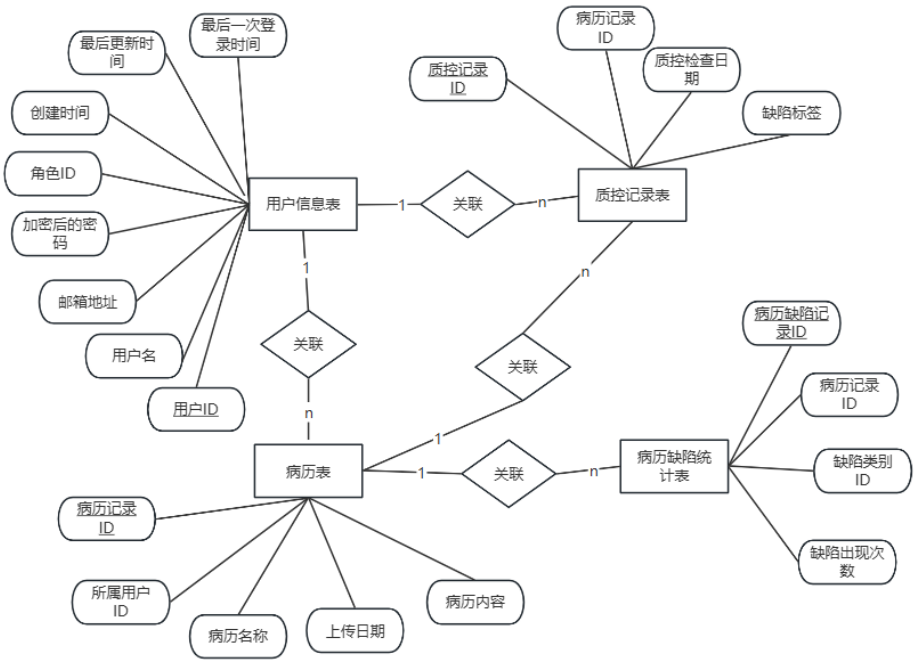


图 5-3 系统部分表 E-R 图

用户信息表部分字段有用户 ID，角色 ID，用户名，邮箱地址，加密后的密码，创建时间，最后更新时间，最后一次登录时间，如表 5-1 所示。

表 5-1 用户信息表

Filed	Type	Key	Auto_Increment	Comment
user_id	int	PK	1	用户 ID
role_id	int	FK	-	角色 ID
username	varchar	UK	-	用户名
email	varchar	UK	-	邮箱地址
password_hash	varchar	-	-	加密后的密码
created_datetime	datetime	-	-	创建时间
modified_datetime	datetime	-	-	最后更新时间
last_login	datetime	-	-	最后一次登录时间

病历表部分字段有病历记录 ID，所属用户 ID，病历名称，上传日期，病历内容，如表 5-2 所示。

中国知网 https://www.cnki.net

表 5-2 病历表

Filed	Type	Key	Auto_Increment	Comment
record_id	int	PK	1	病历记录 ID
user_id	int	FK	-	所属用户 ID
record_name	varchar	-	-	病历名称
upload_date	date	-	-	上传日期
content	text	-	-	病历内容

质控记录表部分字段有质控记录 ID，病历记录 ID，质控检查日期，缺陷标签，如表 5-3 所示。

表 5-3 质控记录表

Filed	Type	Key	Auto_Increment	Comment
check_id	int	PK	1	质控记录 ID
record_id	int	FK	-	病历记录 ID
check_date	datetime	-	-	质控检查日期
risk_tag	varchar	-	-	缺陷标签

病历缺陷统计表部分字段有病历缺陷记录 ID，病历记录 ID，缺陷类别 ID，缺陷出现次数，如表 5-4 所示。

表 5-4 病历缺陷统计表

Filed	Type	Key	Auto_Increment	Comment
risk_id	int	PK	1	病历缺陷记录 ID
record_id	int	FK	-	病历记录 ID
tag_id	int	-	-	缺陷类别 ID
count	int	-	-	缺陷出现次数

5.4.2 Neo4j 数据库设计

Neo4j 是一个高性能的原生图数据库，它专门设计用于存储和查询图形数据结构，如节点、边和属性。这种数据库非常适合处理复杂的关系数据，因为它能够自然地表示数据之间的连接关系。本文通过人工构建知识图谱来提供病历缺陷的修改建议，病历缺陷建议图谱建立流程如图 5-4 所示。

中国知网 https://www.cnki.net

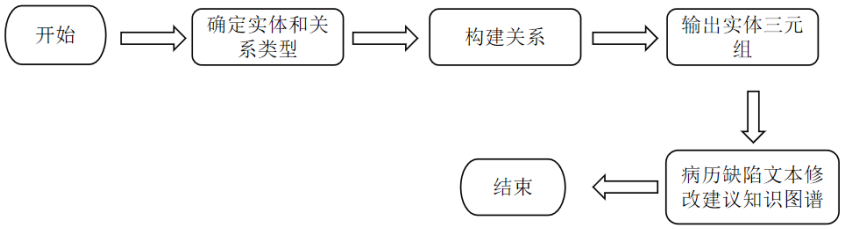


图 5-4 病历缺陷建议图谱建立流程

在构建知识图谱时，需要对实体类型和实体属性以及实体之间的关系类型进行设计，具体设计如表 5-5 至表 5-7 所示。

表 5-5 病历缺陷文本修改建议知识图谱实体类型设计表

实体	说明
病历 ID	表示病历文档
缺陷	表示病历中的缺陷
修改建议	表示针对缺陷的修改建议

表 5-6 病历缺陷文本缺陷修改建议知识图谱属性设计表

属性	说明
病历属性	存储病历 ID 内容
缺陷属性	存储缺陷的类型
修改建议属性	表示针对缺陷的修改建议

表 5-7 病历缺陷文本缺陷修改建议知识图谱关系设计表

关系	举例
病历-缺陷	<病历 ID，病历缺陷，现病史发病情况描述不清>
缺陷-修改建议	<现病史发病情况描述不清，修改建议，应记录发病时间，地点和诱因>

5.5 系统关键功能模块设计

5.5.1 病历缺陷文本检测模块设计

在病历缺陷文本检测阶段，参与的主要类有文本分类模型类（TextClassifier），病历数据类（MedicalRecord），用户认证类（UserAuth），API 端点类（APIEndpoint），安全管理类（SecurityManager），日志记录类（Logger），数据库交互类（Database），病历缺陷检测阶段主要类图如图 5-5 所示。

中国知网 https://www.cnki.net

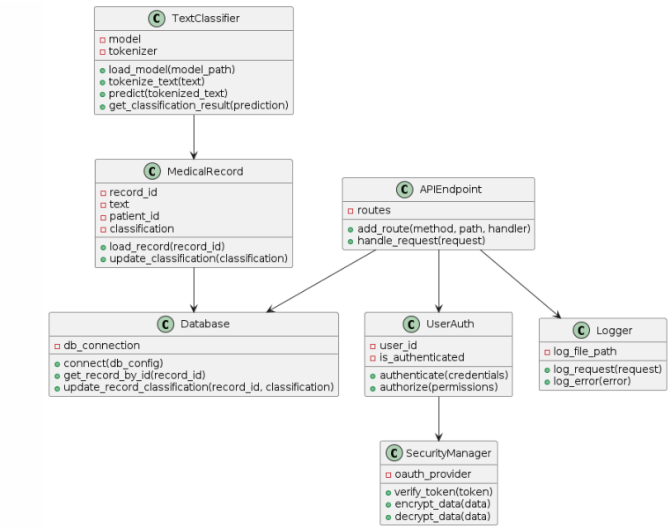


图 5-5 病历缺陷检测阶段主要类图

病历缺陷文本检测阶段主要的类与方法的设计，如表 5-8 所示。

表 5-8 主要的类与方法

主要类	主要方法	方法描述
文本分类模型类	load_model( )、tokenize_text( )、predict( )、get_classification_result( )	加载文本分类模型、病历文本分词处理、文本分类预测、返回分类标签和置信度
用户认证类	authenticate( )、authorize( )	根据提供的凭证对用户进行认证、检查用户是否具有执行某操作的权限
病历数据类	load_record( )、update_classification( )	加载特定病历记录、更新病历的分类结果（对象状态）
API 端点类	add_route( )、handle_request( )	添加新的 API 路由、处理进入的 API 请求
安全管理类	verify_token( )、encrypt_data( )、decrypt_data( )	验证传入的访问令牌、对敏感数据进行加密、对加密的数据进行解密
日志记录类	log_request( )、log_error( )	记录 API 请求的详细信息、记录发生的错误
数据库交互类	connect( )、get_record_by_id( )、update_record_classification( )	使用配置信息建立数据库连接、根据病历 ID 获取病历记录、更新病历记录的分类信息

中国知网 https://www.cnki.net

病历缺陷文本检测模块是负责对病历缺陷文本进行分类，在进行病历缺陷文本检测阶段，TextClassifier 调用 MedicalRecord 加载病历记录进行缺陷检测的时序图如图 5-6 所示。

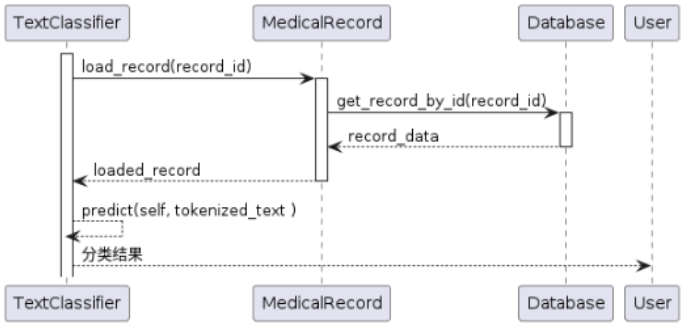


图 5-6 TextClassifier 调用 MedicalRecord 加载病历记录缺陷检测时序图

基于特征融合的文本分类算法关键代码如表 5-9 所示。

表 5-9 基于特征融合的文本分类算法关键代码

代码 5-9　基于特征融合的文本分类算法关键代码

```
1:  encoder_out, text_cls = self.bert(context, attention_mask=mask,
output_all_encoded_layers=False)
2:  lstm_out, _ = self.bilstm(encoder_out)
3:  out_lstm_cnn = torch.cat([out_cnn, lstm_out[:, -1, :]], dim=1)
4:  out_lstm_cnn = self.fc_cnn(out_lstm_cnn)
5:  out_residual = self.fc_residual(text_cls)
6:  out_self_attention = self.self_attention(encoder_out, mask)
7:  out_self_attention = self.fc_residual(out_self_attention)
8:  out = out_lstm_cnn + out_residual + out_self_attention
```

```
主诉：[
        "主诉不规范",
        "主诉错误"
    ]
现病史：[
        "现病史欠缺伴随症状描述",
        "现病史发病情况描述不清",
        "现病史未描述治疗经过及效果",
        "现病史未描述发病以来的一般情况",
        "现病史未描述与鉴别诊断有关的阳性症状",
        "现病史未描述与本次入院有关的重要阴性症状",
        "现病史欠缺疾病发生的先后顺序描述主要症状的部位"
        ]
既往史：[
        "未描述疾病史",
        "未描述传染病史",
        "未描述预防接种史",
        "未描述手术外伤史",
        "未描述输血史",
        "未描述食物过敏史",
        "未描述药物过敏史"
        ]
个人史：[
        "欠缺出生地",
        "欠缺长期居留地",
        "生活习惯不完整",
        "工作条件不完整",
        "欠缺冶游史"
        ]
婚育史：[
        "未描述婚姻状况",
        "未描述配偶健康状况",
        "未描述结婚年龄",
        "未描述有无子女",
        "女性月经史描述不完整"
                ]
```

图 5-7 质控规则库

中国知网 https://www.cnki.net

为了更好地对病历进行质控，根据《绵阳市中心医院住院病历评定标准(试行)》和卫生部印发的《病历书写基本规范》整理了质控规则，形成了一个质控规则库，如图 5-7 所示。

5.5.2 病历缺陷文本辅助修改模块设计

在病历缺陷文本辅助修改阶段，参与的主要类有建议信息管理类（HintManager）、Neo4j 数据库配置类、建议信息格式化类（HintFormatter），如表 5-10 所示。

表 5-10 主要的类与方法

主要类	主要方法与属性	方法描述
建议信息管理类	connect_to_neo4j( )、disconnect_from_neo4j( )、get_hints_for_defect( )	连接到 Neo4j 数据库、断开与 Neo4j 的连接、根据缺陷检索相关的建议信息
Neo4j 数据库配置类	url、user、password	Neo4j 数据库的连接 url、数据库用户名、用户密码
建议信息格式化类	format_hints( )	根据格式化模板格式化建议信息

病历缺陷文本辅助修改时序图如图 5-8 所示，建议信息管理类（HintManager）通过 Neo4j 数据库配置类（Neo4jConfig）建立与数据库的连接，并使用 Neo4j 数据库驱动（Neo4jDriver）执行预定义的查询模板（hint_query）。查询结果由驱动返回给建议信息管理类，然后传递给建议信息格式化类（HintFormatter）进行格式化处理。格式化后的建议信息最终由建议信息管理类传递给用户。

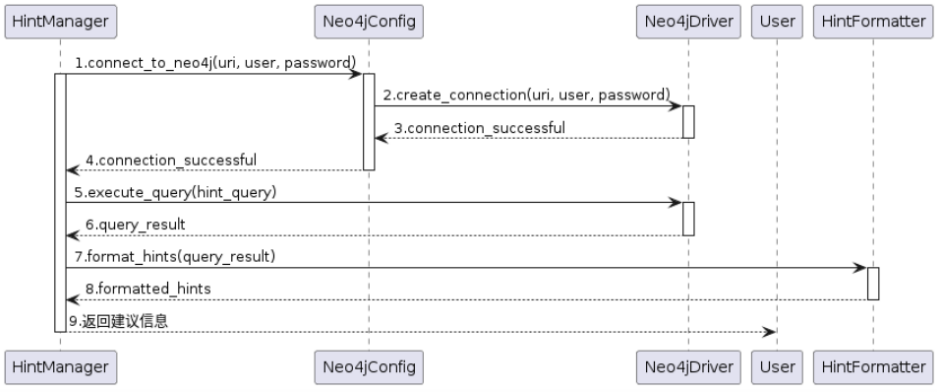


图 5-8 病历缺陷文本辅助修改时序图

病历 M0001 文本缺陷修改建议知识图谱可视化如图 5-9 所示。

中国知网 https://www.cnki.net

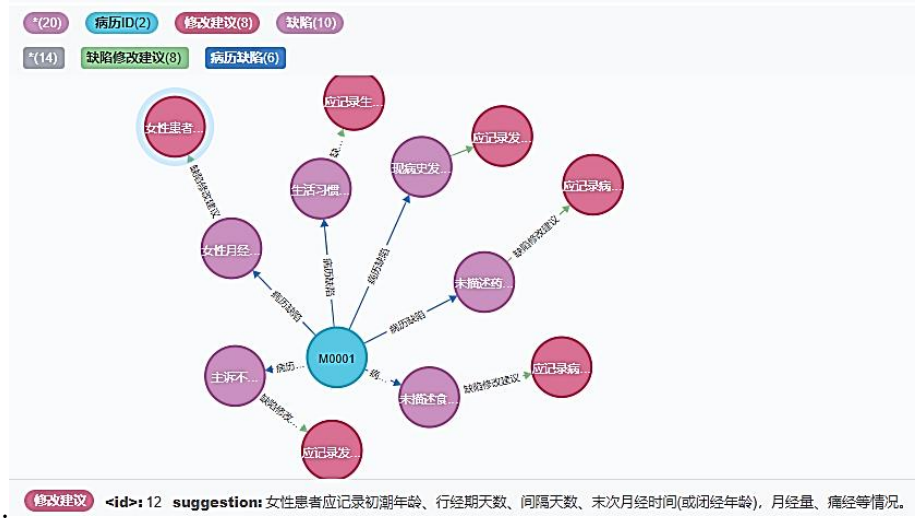


图 5-9 病历 M0001 文本缺陷修改建议知识图谱可视化

5.5.3 病历缺陷条目时间筛选和统计分析模块设计

病历缺陷条目时间筛选和统计分析模块是以柱状图的形式展示统计结果，使用户更直观地了解不同缺陷条目的比例和分布情况。在病历缺陷条目时间筛选和统计分析模块主要参与的类有：缺陷统计分析类(DefectstatisticsAnalyzer)，数据源类(DataSource)，统计结果类(StatisticsResult)，如表 5-11 所示。

表 5-11 主要的类与方法

主要类	主要方法	方法描述
缺陷统计分析类	set_time_filter( )、calculate_statistics( )、generate_bar_chart( )	设置时间筛选条件、计算缺陷的总数和各类缺陷的出现次数、生成柱状图以展示统计结果
数据源类	query_defects( )	数据源查询并返回缺陷数据
统计结果类	add_defect_count( )、set_total_defects( )、calculate_all_percentages( )	更新缺陷计数、更新缺陷总数、计算所有缺陷类型的百分比

病历缺陷条目时间筛选和统计分析时序图如图 5-10 所示。用户通过调用缺陷统计分析类的方法设置时间筛选条件，获取缺陷数据，并获得统计结果，最终生成柱状图展示缺陷类型的百分比。

中国知网 https://www.cnki.net

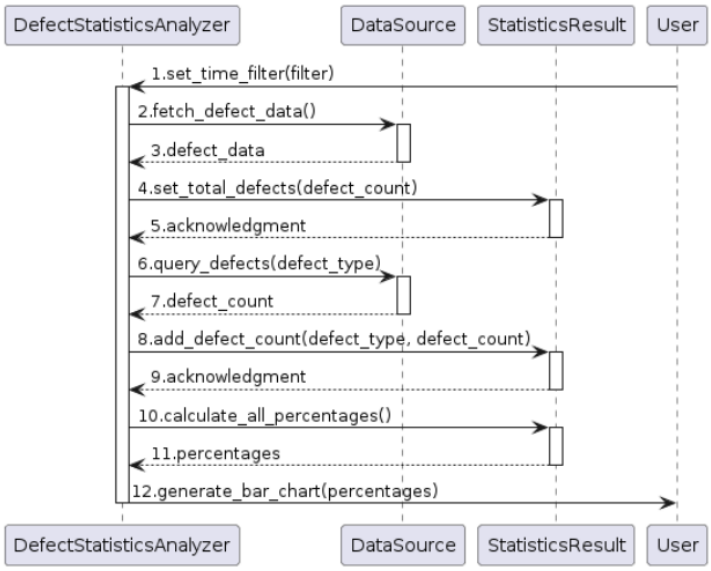


图 5-10 病历缺陷条目时间筛选和统计分析时序图

5.6 系统实现与测试

5.6.1 病历缺陷文本检测与辅助修改功能的实现与测试

系统中的待审核病历列表页面展示如图 5-11 所示，而作为系统的核心功能，病历缺陷文本的检测与辅助修改界面详见图 5-12。在页面左侧，原始病历文本被直接展示给质控医生，以便进行细致的查看与评估。相对应地，页面右侧展示的是质控结果，系统能够自动检测病历中的缺陷，并针对每个缺陷提供相应的修改建议。质控医生可以通过编辑按钮对系统提供的修改建议进行进一步的详细说明，利用删除功能移除掉错误识别的缺陷，或通过“新增”按钮来补充系统未能识别的病历缺陷。这些功能的灵活性共同确保了质控结果的准确性和完整性。

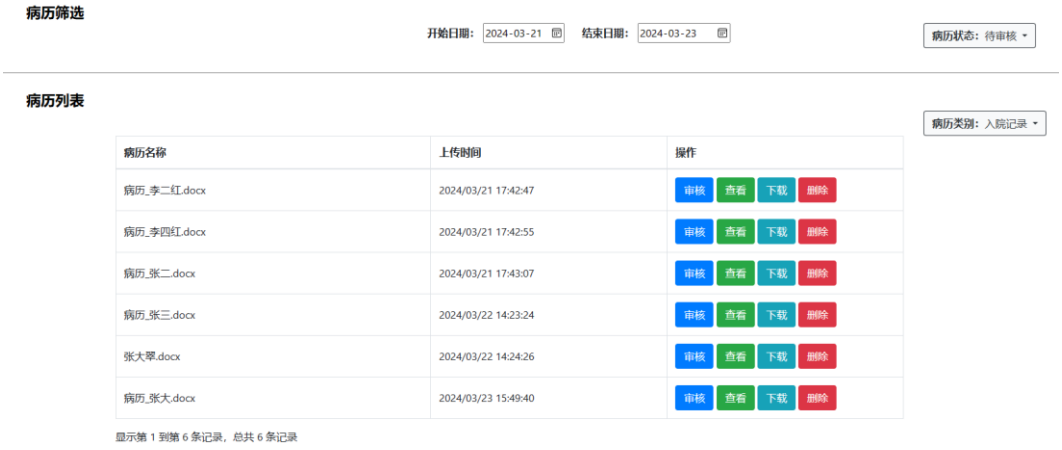


图 5-11 待审核病历列表界面

中国知网 https://www.cnki.net



图 5-12 病历质控界面

关于病历缺陷文本检测功能和辅助修改功能的测试用例表，具体展示如表 5-12 和表 5-13 所示。

表 5-12 病历缺陷文本检测功能测试用例表

测试内容	前置条件	测试操作	预期结果	实际结果
上传包含已知缺陷的病历文档，验证系统是否能够正确识别并分类病历缺陷	系统已部署并可访问病历缺陷文本检测页面	上传一个包含已知缺陷的病历文档，到待审核页面点击审核按钮，然后到已审核界面点击查看按钮	系统应能够正确识别缺陷并分类80%左右的病历缺陷，将其报告出来	与预期结果一致

表 5-13 病历缺陷文本辅助修改功能测试用例表

测试内容	前置条件	测试操作	预期结果	实际结果
包含已知缺陷的病历文档，根据检测到的缺陷类别，验证系统是否能够提供正确的修改建议	系统已部署并可访问病历缺陷文本检测页面	上传一个已知包含缺陷的病历文档，到待审核页面点击审核按钮，然后到已审核界面点击查看按钮	根据识别出的每个缺陷类别提供相应的修改建议	与预期结果一致

5.6.2 病历缺陷条目时间筛选和统计分析功能的实现与测试

根据具体需求，系统可以提供时间筛选功能，以便按照时间范围筛选病历缺陷条

中国知网 https://www.cnki.net

目数据。用户可以选择特定时间段进行筛选。即用户可以选择起始日期和结束日期，系统将筛选出在该时间段内的病历缺陷条目数据。一旦完成时间筛选，系统将返回符合要求的病历缺陷条目数据。这些数据可以用于进一步的统计分析。在统计分析阶段，系统可以提供以下功能：

（1）缺陷条目比例统计：对筛选出的数据进行分析，计算不同缺陷条目在特定时间范围内的比例。系统可以展示出每个缺陷条目的比例，以便用户了解病历缺陷文本普遍出现的地方。

（2）可视化展示：系统以柱状图的形式展示统计结果，使用户更直观地了解不同缺陷条目的比例和分布情况。



图 5-13 病历缺陷分布占比

表 5-14 病历缺陷条目时间筛选和统计分析功能测试用例表

测试内容	前置条件	测试操作	预期结果	实际结果
选择特定时间段，验证系统是否能够正确筛选出该时间段内的缺陷条目	系统已部署并可访问病历缺陷条目时间筛选和统计分析页面	打开已审核病历缺陷条目时间筛选和统计分析页面，选择特定的时间段	系统正确筛选出缺陷条目，并展示相应的结果	与预期结果一致
验证系统是否正确展示不同缺陷条目的比例情况			系统正确计算出不同缺陷条目的比例情况并进行了展示	与预期结果一致

通过以上功能，用户可以根据具体时间范围筛选出符合要求的病历缺陷条目数据，并进行统计分析，从而深入了解病历缺陷文本的分布情况和普遍出现的地方。这有助

中国知网 https://www.cnki.net

于指导质控工作，并提供改进病历质量的参考依据。效果展示如图 5-13 所示，病历缺陷条目时间筛选和统计分析功能测试用例表如表 5-14 所示。

5.6.3 系统非功能性测试

病历内涵质量控制系统的非功能性需求分析主要集中于保障系统的性能和安全性。性能测试的目的是确保系统能够高效地处理数据，满足用户对于响应时间和数据处理速度的期望。安全性测试则旨在确保系统能够安全地存储和传输敏感的医疗信息，防止未授权访问和数据泄露，测试用例表如表 5-15 所示。

表 5-15 系统非功能性测试用例表

测试内容	前置条件	测试操作	预期结果	实际结果
系统性能	系统已启动且可访问	上传数个病历文件	每个病历上传响应时间在 1 秒内	与预期结果一致
系统性能	系统已启动且有可检索的病历数据	搜索指定时间段的病历	病历搜索响应时间在 1 秒内	与预期结果一致
系统性能	系统已启动且有质控处理功能	执行质控处理操作	质控流程响应时间在 6 秒内完成	与预期结果一致
系统安全性	系统已启动且有访问控制功能	尝试访问敏感信息	只有经过授权的用户能够访问敏感信息	与预期结果一致
系统安全性	系统已启动且有用户身份验证机制	使用有效凭据进行登录	登录成功	与预期结果一致
系统安全性	用户已登录系统	将会话保持一段时间，等待超时	会话在非活动状态下自动注销	与预期结果一致

5.7 本章小结

本章详细介绍了病历内涵质控系统的设计与实现过程。首先，对系统进行了需求分析，然后对系统整体架构进行了规划，包括前端表现层、业务逻辑处理层及物理数据层。在数据持久化存储方面，根据系统业务需求，设计了 MySQL 数据库表结构，并针对 Neo4j 数据库进行了专门的设计。随后，对系统的功能模块进行了设计，其中详细介绍了病历缺陷文本检测模块、病历缺陷文本辅助修改模块，以及病历缺陷条目时间筛选和统计分析模块的设计方案。最终，本章还展示了内涵质控系统的功能实现，并进行了系统测试，以验证各项功能的准确性和有效性。

中国知网 https://www.cnki.net

6 结论与展望

针对传统人工电子病历质量控制方法所面临的挑战，如审核速度慢和效率低的问题，本文聚焦于对中文电子病历展开内涵质控的技术研究与应用。本研究旨在利用深度学习技术，实现病历内涵质量控制的高效自动化。本文的主要工作如下：

(1) 本文完成了一个高质量的病历内涵缺陷标注语料库的构建。首先，通过互联网收集病历，并对其进行数据清洗。其次，结合《绵阳市中心医院住院病历评定标准(试行)》和卫生部印发的《病历书写基本规范》对病历文本进行标注分类。接着，根据对构建完成的病历缺陷文本语料进行数据分析，验证其可用性。最终建立了一个高质量的病历标注语料库，为病历质控领域的自然语言处理研究提供了坚实的基础和支持。

(2) 本文提出了一种基于特征融合的文本分类模型。该模型采用了 BERT 技术来增强对句子整体含义的理解能力。同时，通过结合双向长短期记忆神经网络和文本卷积神经网络，模型能够捕捉文本中的双向语义信息，并有效提取局部特征，从而解决了病历文本中上下文关系的复杂性和关键信息的提取难题。此外，为了更有效地提取病历文本的关键特征，并减少信息在网络传递过程中的损失，模型还融入了自注意力机制和残差连接技术。模型在本文构建的病历内涵缺陷文本数据集上进行了实验验证，实验结果充分证明了该模型在病历缺陷文本分类任务中的有效性和可行性。

(3)设计并实现了一个病历内涵质控系统，该系统集成了本文提出的基于特征融合的文本分类模型，实现了核心的病历缺陷自动检测功能。为了提升用户体验并满足日常使用需求，系统还提供了一系列辅助功能。这些功能包括提供病历缺陷的修改建议、展示病历缺陷的分布情况、编辑现有的修改建议、移除系统错误识别的缺陷，以及补充系统未能自动识别的病历缺陷等。这些功能的集合不仅增强了用户的使用体验，也提高了病历内涵质控的效率和准确性。

在未来的研究中，将计划在两个主要方向上对电子病历内涵质控进行更深入的探索。首先，鉴于当前研究使用的数据主要来自互联网，存在数据基础薄弱和数据量不足的问题，且未对门诊和住院等不同类型的病案进行分类描述，所以在未来计划扩大数据来源，增加数据量，并针对不同种类的病案进行更细致的研究，以提高研究的实用性。其次将探索篇章级病历质控的算法。目前，研究主要集中在病历文本语句的缺陷检测上，而对于整个病历篇章的质量和一致性评估尚未进行深入研究。未来将考虑整合结构化和非结构化信息，对篇章级病历内涵质控算法进行研究。

中国知网 https://www.cnki.net

参考文献

[1] Lin W C, Chen J S, Chiang M F, et al. Applications of artificial intelligence to electronic health record data in ophthalmology[J]. Translational vision science & technology, 2020, 9(2): 13-13.

[2] 马锡坤, 杨国斌, 于京杰等. 国内电子病历发展与应用现状分析[J]. 计算机应用与软件, 2015, 32(1): 10-12.

[3] S Tokosi T O. Electronic patient record (EPR) system in South Africa: information, storage, retrieval and share amongst clinicians[J]. 2016.

[4] Tayefi M, Ngo P, Chomutare T, et al. Challenges and opportunities beyond structured data in analysis of electronic health records[J]. Wiley Interdisciplinary Reviews: Computational Statistics, 2021, 13(6): e1549.

[5] Sarwar T, Seifollahi S, Chan J, et al. The secondary use of electronic health records for data mining: Data characteristics and challenges[J]. ACM Computing Surveys (CSUR), 2022, 55(2): 1-40.

[6] Cheng Y, Wang F, Zhang P, et al. Risk prediction with electronic health records: A deep learning approach[C]//Proceedings of the 2016 SIAM international conference on data mining. Society for Industrial and Applied Mathematics, 2016: 432-440.

[7] Moskalev I V, Krotova O S, Khvorova L A, et al. Extraction of structured data from unstructured medical records using text data mining technologies: process automation[C]//Journal of Physics: Conference Series. IOP Publishing, 2020, 1615(1): 012031.

[8] YU Y, TANG Y, ZHANG Y, et al. Application of medical record quality control system in blood transfusion records[J]. Basic & Clinical Medicine, 2021, 41(10): 1554.

[9] 田军, 王云超, 包士忻等.病历质量管控模式构建与研究[J].中国研究型医院,2020,7(5):63-66.

[10] 赵静.电子病案质控存在问题分析及改进措施[J].中国药物与临床,2018,18(02):291-292.

[11] 金和风, 钟初雷.实时监控电子病历的实现[J].中华医院管理杂志,2006,22(4):261-262.

[12] 李晓明, 王永辉, 任子娟等.基于规则引擎的电子病历前置质控系统设计与应用[J].医疗卫生装备,2019,40(02):47-51.

[13] 张瑜, 吴青松, 胡和等.基于人工智能的全程病历质控系统的构建与应用[J].中国数字医学,2022,17(10):83-87.

[14] 温煜,李雄,曾菲菲,等.基于人工智能的病历质控系统的应用研究[J].四川大学学报(医学版),2023,54(06):1263-1268.DOI:10.12182/20231160206.

[15] Zhang Y, Jin R, Zhou Z H. Understanding bag-of-words model: a statistical framework[J]. International Journal of Machine Learning and Cybernetics, 2010, 1(1): 43-52.

中国知网 https://www.cnki.net

[16] Al-Shehari T, Alsowail R A. An Insider Data Leakage Detection Using One-Hot Encoding, Synthetic Minority Oversampling and Machine Learning Techniques[J].Entropy, 2021, 23(10): 1258.

[17] Wang X, Ning H. TF-IDF Keyword Extraction Method Combining Context and Semantic Classification[C]//Proceedings of the 3rd International Conference on Data Science and Information Technology. 2020: 123-128.

[18] Cavnar W B, Trenkle J M. N-gram-based text categorization[C]//Proceedings of SDAIR-94, 3rd annual symposium on document analysis and information retrieval. 1994, 161175.

[19] Hinton G E. Learning distributed representations of concepts[C]//Proceedings of the eighth annual conference of the cognitive science society. 1986, 1: 12.

[20] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv: 1301.3781, 2013.

[21] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]//Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014: 1532-1543.

[22] Peters M E, Neumann M, Iyyer M, et al. Deep contextualized word representations. arXiv preprint arXiv: 180205365[J]. 2018.

[23] Radford A, Narasimhan K, Salimans T, et al. Improving language understanding by generative pre-training[J]. Computer Science, 2018.

[24] Chitty-Venkata K T, Mittal S, Emani M, et al. A survey of techniques for optimizing transformer inference[J]. Journal of Systems Architecture, 2023: 102990.

[25] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv: 1810.04805, 2018.

[26] Yang Z, Dai Z, Yang Y, et al. Xlnet: Generalized autoregressive pretraining for language understanding[J].Advances in neural information processing systems, 2019, 32.

[27] Umer M, Imtiaz Z, Ahmad M, et al. Impact of convolutional neural network and FastText embedding on text classification[J]. Multimedia Tools and Applications, 2023, 82(4): 5569-5585

[28] Mutinda J, Mwangi W, Okeyo G. Sentiment analysis of text reviews using lexicon-enhanced bert embedding (LeBERT) model with convolutional neural network[J]. Applied Sciences, 2023, 13(3): 1445.

[29] Kim Y.Convolutional neural networks for sentence classification[J]. arXiv preprint arXiv: 1408.5882.,2014.

[30] ZHANG X，ZHAO J B, LECUN Y. Character-level convolutional networks for text classification [C]//Proceedings of the 28th International Conference on Neural Information Processing Systems.2015: 649-657.

中国知网 https://www.cnki.net

[31] Ma M, Huang L, Xiang B，et al. Dependency based convolutional neural networks for sentence embedding [C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing. 2015. DOI: 10. 3115 /V1 /P15-2029.

[32] Guo B, Zhang C, Liu J, et al. Improving text classification with weighted word embeddings via a multi-channel TextCNN model[J]. Neurocomputing, 2019, 363: 366-374.

[33] Enamoto L, Weigang L, Filho G P R. Generic framework for multilingual short text categorization using convolutional neural network[J]. Multimedia Tools and Applications, 2021, 80(9): 13475-13490

[34] Soni S, Chouhan S S, Rathore S S. TextConvoNet: A convolutional neural network based architecture for text classification[J]. Applied Intelligence, 2023, 53(11): 14249-14268.

[35] Qorich M, El Ouazzani R. Text sentiment classification of Amazon reviews using word embeddings and convolutional neural networks[J]. The Journal of Supercomputing, 2023, 79(10): 11029-11054

[36] Tai K S, Socher R, Manning C D. Improved semantic representations from tree-structured long short-term memory networks[J]. arXiv preprint arXiv:1503.00075, 2015.

[37] Zhou P, Qi Z, Zheng S, et al. Text classification improved by integrating bidirectional LSTM with two-dimensional max pooling[J]. arXiv preprint arXiv:1611.06639, 2016

[38] Dieng A B, Wang C, Gao J, et al. Topicrnn: A recurrent neural network with long-range semantic dependency[J]. arXiv preprint arXiv:1611.01702, 2016.

[39] Johnson R, Zhang T. Supervised and semi-supervised text categorization using LSTM for region embeddings[C]//International Conference on Machine Learning. PMLR, 2016: 526-534.

[40] Edara D C, Vanukuri L P, Sistla V, et al. Sentiment analysis and text categorization of cancer medical records with LSTM[J]. Journal of Ambient Intelligence and Humanized Computing, 2023, 14(5): 5309-5325.

[41] Zulqarnain M, Ghazali R, Aamir M, et al. An efficient two-state GRU based on feature attention mechanism for sentiment analysis[J]. Multimedia Tools and Applications, 2024, 83(1): 3085-3110.

[42] Yang L, Ai Q, Guo J, et al. anmm: Ranking short answer texts with attention-based neural matching model[C]//Proceedings of the 25th ACM international on conference on information and knowledge management. 2016: 287-296.

[43] Yin W, Schütze H, Xiang B, et al. Abcnn: Attention-based convolutional neural network for modeling sentence pairs[J]. Transactions of the Association for Computational Linguistics, 2016, 4: 259-272.

[44] Lin Z, Feng M, Santos C N, et al. A structured self-attentive sentence embedding[J]. arXiv preprint arXiv:1703.03130, 2017.

[45] Chen Q, Ling Z H, Zhu X. Enhancing sentence embedding with generalized pooling[J]. arXiv preprint arXiv:1806.09828, 2018.

中国知网 https://www.cnki.net

[46] Kim S, Kang I, Kwak N. Semantic sentence matching with densely-connected recurrent and co-attentive information[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 6586-6593.

[47] 李卫疆, 漆芳, 余正涛.基于多通道特征和自注意力的情感分类方法[J].软件学报,2021,32(09):2783-2800.

[48] Huang Y, Dai X, Yu J, et al. SA-SGRU: combining improved self-attention and skip-GRU for text classification[J]. Applied Sciences, 2023, 13(3): 1296.

[49] Li G, Zhao X, Wang X. Quantum self-attention neural networks for text classification[J]. Science China Information Sciences, 2024, 67(4): 1-13.

[50] Kadhim A I. Survey on supervised machine learning techniques for automatic text classification[J]. Artificial intelligence review, 2019, 52(1): 273-292.

[51] Wang B, Wang A, Chen F, et al. Evaluating word embedding models: Methods and experimental results[J]. APSIPA transactions on signal and information processing, 2019, 8: e19.

[52] 常建秋, 沈炜. 基于字符串匹配的中文分词算法的研究[J]. 工业控制计算机, 2016 (2): 115-116.

[53] 邹佳伦, 文汉云, 王同喜. 基于统计的中文分词算法研究[J]. 电脑知识与技术, 2019, 15(4): 155-156.

[54] 张丹.中文分词算法综述[J].黑龙江科技信息,2012(08):206.

[55] Gan C, Wang L, Zhang Z. Multi-entity sentiment analysis using self-attention based hierarchical dilated convolutional neural network[J]. Future Generation Computer Systems, 2020, 112: 116-125.

[56] Wang Y, Yang G, Li S, et al. Arrhythmia classification algorithm based on multi-head self-attention mechanism[J]. Biomedical Signal Processing and Control, 2023, 79: 104206.

[57] Liang Y, Li H, Guo B, et al. Fusion of heterogeneous attention mechanisms in multi-view convolutional neural network for text classification[J]. Information Sciences, 2021, 548: 295-312.

中国知网 https://www.cnki.net